Politechnika Wrocławska

Wydział Matematyki
Kierunek studiów: Matematyka stosowana
Specjalność: –

Praca dyplomowa – inżynierska

METODY UCZENIA MASZYNOWEGO W ROZPOZNAWANIU INSTRUMENTÓW MUZYCZNYCH

Agata Sobczak

słowa kluczowe:
uczenie maszynowe, klasyfikacja, instrumenty muzyczne, rozpoznawanie dźwięków, algorytmy

krótkie streszczenie:
Niniejsza praca obejmuje budowę i implementację modeli uczenia maszynowego do rozpoznawania instrumentów muzycznych. Pierwsza część pracy skupia się na podstawowych pojęciach uczenia maszynowego, analizie danych oraz opisach wykorzystywanych algorytmów. Druga część pracy skupia się na wynikach osiągniętych w trakcie przeprowadzanych analiz oraz końcowym podsumowaniu rezultatów.

Opiekun pracy dyplomowej	dr Kamil Bogus	.....	.....
	Tytuł/stopień naukowy/imię i nazwisko	ocena	podpis

*Do celów archiwalnych pracę dyplomową zakwalifikowano do:**

a) kategorii A (akta wieczyste)

b) kategorii BE 50 (po 50 latach podlegające ekspertyzie)

** niepotrzebne skreślić*

pieczątka wydziałowa

Wrocław, rok 2025

Wrocław University
of Science and Technology

Faculty of Pure and Applied Mathematics
Field of study: Applied Mathematics
Specialty: –

Engineering Thesis

MACHINE LEARNING TECHNIQUES FOR MUSICAL INSTRUMENTS RECOGNITION

Agata Sobczak

keywords:
machine learning, classification, instruments, sound recognition, algorithms

short summary:
This work covers the construction and implementation of machine learning models for musical instrument recognition. The first part of the work focuses on the theory of basic machine learning concepts, data analysis, and descriptions of the algorithms used. The second part of the work focuses on the results achieved during the conducted analyses and the final summary of the results.

Supervisor	dr Kamil Bogus	.....	.....
	Title/degree/name and surname	grade	signature

*For the purposes of archival thesis qualified to:**

a) category A (perpetual files)

b) category BE 50 (subject to expertise after 50 years)

** delete as appropriate*

stamp of the faculty

Wrocław, 2025

Spis treści

1 Wstęp **7**

2 Uczenie maszynowe **9**
2.1 Uczenie nadzorowane . . . 9
2.2 Uczenie nienadzorowane . . . 10
2.3 Uczenie przez wzmacnianie . . . 10
2.4 Ewaluacja modeli . . . 11

3 Modele **13**
3.1 Losowy model bazowy . . . 13
3.2 Regresja logistyczna . . . 14
3.3 Naiwny klasyfikator Bayesa . . . 16
3.4 Metoda K - najbliższych sąsiadów . . . 17
3.5 Drzewo decyzyjne i jego wzmocnienia . . . 18
3.5.1 Wzmocnienia . . . 19
3.6 Maszyna wektorów nośnych . . . 20
3.7 Sieci neuronowe . . . 22

4 Przetwarzanie i analiza danych **25**
4.1 Zbiór danych i ich przetwarzanie . . . 25
4.2 Ekstrakcja współczynników MFCC . . . 26
4.3 Analiza zbioru danych . . . 27

5 Analizy **35**
5.1 Losowy model bazowy . . . 35
5.2 Regresja logistyczna . . . 37
5.3 Naiwny klasyfikator Bayesa . . . 39
5.4 Metoda K - najbliższych sąsiadów . . . 41
5.5 Drzewo decyzyjne i jego wzmocnienia . . . 43
5.5.1 Wzmocnienia . . . 45
5.6 Maszyna wektorów nośnych . . . 47
5.7 Sieci neuronowe . . . 49
5.8 Eksperymenty . . . 51

6 Podsumowanie **55**

7 Dodatek **57**

Bibliografia **58**

Spis tabel

2.1 Macierz pomyłek. 11

3.1 Wykorzystywana notacja w problemie klasyfikacji. 13
3.2 Wybrane metody regularyzacji: Źródło [17]. 15
3.3 Wybrane klasyfikatory wariantów Naiwnego Bayesa. 17

4.1 Wybrane statystyki dla 13 współczynników capstralnych Mel dla klasyfikowanych instrumentów. 29
4.2 Wybrane statystyki dla 13 współczynników capstralnych Mel dla klasyfikowanych instrumentów. 30

5.1 Podstawowe metryki modelu bazowego. 35
5.2 Raport klasyfikacji instrumentów dla modelu bazowego. 36
5.3 Najlepsze modele regresji logistycznej dla każdej metryki. 37
5.4 Podstawowe metryki najlepszego modelu regresji logistycznej. 37
5.5 Raport klasyfikacji instrumentów najlepszego modelu regresji logistycznej. 38
5.6 Najlepsze modele naiwnego klasyfikatora Bayesa dla każdej metryki. 39
5.7 Podstawowe metryki najlepszego modelu naiwnego klasyfikatora Bayesa. . 39
5.8 Raport klasyfikacji instrumentów dla najlepszego modelu naiwnego klasyfikatora Bayesa. 40
5.9 Najlepsze modele dla każdej metryki dla metody K - najbliższych sąsiadów. 41
5.10 Podstawowe metryki najlepszego modelu metody K - najbliższych sąsiadów. 41
5.11 Raport klasyfikacji instrumentów dla najlepszego modelu metody K - najbliższych sąsiadów. 42
5.12 Najlepsze modele dla każdej metryki dla drzewa decyzyjnego. 43
5.13 Podstawowe metryki najlepszego modelu drzewa decyzyjnego. 43
5.14 Raport klasyfikacji instrumentów dla najlepszego modelu drzewa decyzyjnego. 44
5.15 Najlepsze modele dla każdej metryki dla lasu losowego. 45
5.16 Najlepsze modele dla każdej metryki dla Baggingu. 45
5.17 Najlepsze modele dla każdej metryki dla Boostingu. 45
5.18 Podstawowe metryki najlepszego modelu lasu losowego. 46
5.19 Raport klasyfikacji instrumentów dla najlepszego modelu lasu losowego. . . 46
5.20 Najlepsze modele dla każdej metryki dla SVM. 47
5.21 Podstawowe metryki najlepszego modelu SVM. 47
5.22 Raport klasyfikacji instrumentów dla najlepszego modelu SVM. 48
5.23 Najlepsze modele sieci neuronowej dla każdej metryki. 49
5.24 Podstawowe metryki najlepszego modelu sieci neuronowej. 49
5.25 Raport klasyfikacji instrumentów dla najlepszego modelu sieci neuronowej. 50

5.26 Wyniki eksperymentów najlepszych modeli regresji logistycznej przy wyodrębnieniu 30 i 50 cech MFCC. 51
5.27 Wyniki eksperymentów najlepszych modeli regresji logistycznej przy użyciu 3 i 5 sekundowych plików audio. 51
5.28 Wyniki eksperymentów najlepszych modeli naiwnych klasyfikatorów Bayesa przy wyodrębnieniu 30 i 50 cech MFCC. 52
5.29 Wyniki eksperymentów najlepszych modeli naiwnych klasyfikatorów Bayesa przy użyciu 3 i 5 sekundowych plików audio. 52
5.30 Wyniki eksperymentów najlepszych modeli metody K - najbliższych sąsiadów przy wyodrębnieniu 30 i 50 cech MFCC. 52
5.31 Wyniki eksperymentów najlepszych modeli metody K - najbliższych sąsiadów przy użyciu 3 i 5 sekundowych plików audio. 52
5.32 Wyniki eksperymentów najlepszych modeli drzewa decyzyjnego przy wyodrębnieniu 30 i 50 cech MFCC. 53
5.33 Wyniki eksperymentów najlepszych modeli drzewa decyzyjnego przy użyciu 3 i 5 sekundowych plików audio. 53
5.34 Wyniki eksperymentów najlepszych modeli drzewa decyzyjnego ze wzmocnieniami przy przy wyodrębnieniu 30 i 50 cech MFCC. 53
5.35 Wyniki eksperymentów najlepszych modeli drzewa decyzyjnego ze wzmocnieniami przy użyciu 3 i 5 sekundowych plików audio. 53
5.36 Wyniki eksperymentów najlepszych modeli maszyny wektorów nośnych przy wyodrębnieniu 30 i 50 cech MFCC. 54
5.37 Wyniki eksperymentów najlepszych modeli maszyny wektorów nośnych przy użyciu 3 i 5 sekundowych plików audio. 54
5.38 Wyniki eksperymentów najlepszych modeli sieci neuronowych przy wyodrębnieniu 30 i 50 cech MFCC. 54
5.39 Wyniki eksperymentów najlepszych modeli sieci neuronowych przy użyciu 3 i 5 sekundowych plików audio. 54

6.1 Zbiór metryki dokładności i czasu treningu najlepszych przedstawicieli analizowanych algorytmów. 55

Spis rysunków

2.1 Przykład uczenia nadzorowanego. 9
2.2 Przykład uczenia nienadzorowanego. 10
2.3 Przykład uczenia przez wzmacnianie. 10

3.1 Przykładowa klasyfikacja OvR: Źródło [35]. 15
3.2 Przykładowy schemat klasyfikacji w KNN: Źródło [45]. 18
3.3 Schemat blokowy drzewa decyzyjnego [24]. 18
3.4 Przykład drzewa decyzyjnego: Źródło [44]. 19
3.5 Przykład klasyfikacji obiektów w SVM [11]. 21
3.6 Schemat sieci neuronowej [32]. 22

4.1 Oryginalna liczebność plików .wav przed obróbką 25
4.2 Liczebność plików .wav po obróbce 26
4.3 Diagram etapów ekstrakcji współczynników MFCC 26
4.4 Zbiór wykresów pudełkowych współczynników cepstralnych Mel ($MFFC_0$ – $MFFC_5$). 31
4.5 Zbiór wykresów pudełkowych dla współczynników cepstralnych Mel ($MFFC_6$ – $MFFC_{12}$). 32

5.1 Macierz pomyłek losowego modelu bazowego. 36
5.2 Macierz pomyłek najlepszego modelu regresji logistcznej. 38
5.3 Macierz pomyłek najlepszego modelu naiwnego klasyfikatora Bayesa. . . . 40
5.4 Macierz pomyłek najlepszego modelu metody K - najbliższych sąsiadów. . 42
5.5 Macierz pomyłek najlepszego modelu drzewa decyzyjnego. 44
5.6 Macierz pomyłek najlepszego modelu lasu losowego. 46
5.7 Macierz pomyłek najlepszego modelu SVM. 48
5.8 Macierz pomyłek najlepszego modelu sieci neuronowej. 50

Rozdział 1

Wstęp

Sztuczna inteligencja rozwija się w obenych czasach w zawrotnym tempie. Współczesna informatyka znajduje wszechstrone zastosowanie uczenia maszynowego w wielu dziedzinach życia codziennego, a w tym również muzyki. Rozpoznawanie instrumentów muzycznych to znacząca kwestia, szczególnie w kontekście analizy dźwiękowej, automatycznego tagowania utworów oraz projektowania rekomendacji muzycznych. Znaczenie tego tematu rośnie, jest potrzeba cyfrowej analizy dźwięków utworów muzycznych i atomatycznego klasyfikowania dużych zbiorów danych dźwiękowych.

Badania zrealizowane przez Masooda, Khana i Gupta [23] wykazały, że sieci neuronowe, użyte do klasyfikacji 5 instrumentów uzyskały dokładność na poziomie 89% wykorzystując 8 wyodrębnionych cech dźwięków. Yuqing Su w swojej pracy [39] wykorzystała algorytmy metody K - najbliższych sąsiadów, maszyny wektorów nośnych oraz sieci neuronowych do problemu klasyfikacji 7 instrumentów przy użyciu wyekstrahowanych cech MFCC. Modele uzyskały kolejno 93%, 73% oraz 88% dokładności.

Celem pracy jest ogólne zapoznanie się ze standardowymi algorytmami uczenia maszynowego w dziedzinie analizy dźwięków i sprawdzenie ich działania na rzeczywistych danych w problemie klasyfikacji instrumentów muzycznych. Wykorzystany zbiór danych pochodzi ze strony *Kaggle* [25]. Zbiór zawiera dźwięki bębna, gitary, fortepianiu i skrzypiec. Praca z danymi polega na odpowiednim przygotowaniu przykładów oraz ekstrakcji cech MFCC. Do klasyfikacji instrumentów muzycznych użyto popularnych algorytmów, takich jak losowy model bazowy, regresja logistyczna, naiwny klasyfikator Bayesa, metoda K - najbliższych sąsiadów, drzewa decyzyjne i ich wzmocnienia, maszyna wektorów nośnych oraz sieci neuronowe. Głównym zamiarem jest ocena jakości każdego z modeli i wskazanie najefektywniejszego podejścia do rozważanego problemu.

W skład pracy wchodzą 4 rozdziały, podsumowanie, dodatek oraz bibliografia. W rozdziale pierwszym zaprezentowano rodzaje uczenia maszynowego oraz używane w pracy miary jakości. Rozdział drugi obejmuje opisy użytych algorytmów. W rozdziale trzecim znajduje się opis przetwarzania użytych danych oraz ich analiza. Rozdział czwarty zawiera wyniki analiz oraz dodatkowe eksperymenty. W podsumowaniu znajdują się ogólne wnioski oraz pomysły na rozszerzenie tego projektu w przyszłości. Dodatek zawiera informacje o specyfikacji sprzętowej, języku programowania, użytych bibliotek oraz link do reporytorium GitHub.

Rozdział 2

Uczenie maszynowe

Uczenie maszynowe (ang. *machine learning*) jest dziedziną nauki dającą komputerom szansę uczenia się bez wyraźnego wydawania instrukcji. Celem uczenia maszynowego jest uczenie się z danych i służy do uczenia maszyn jak obsługiwać dane efektywnie. Wiele branż wykorzystuje je w celu wyodrębnienia i doboru właściwych danych [4].
Wyróżnia się 3 główne typy uczenia maszynowego: nadzorowane, nienadzorowane i przez wzmacnianie.

2.1 Uczenie nadzorowane

Uczenie nadzorowane (ang. *supervised learning*) polega na uczeniu modelu przy użyciu danych wejściowych z odpowiadającymi im etykietami, które wskazują prawidłowe odpowiedzi [20]. Na podstawie tych danych model uczy się, jak przewidywać właściwą etykietę (w przypadku problemu klasyfikacji) lub (w przypadku problemu regresji) uczy się przewidywać szacowaną wartość wyjściową.

Przykład uczenia maszynowego został zaprezentowany na Rys. 2.1. Widoczny jest zestaw zdjęć 3 zwierząt: kotków, piesków i jeżyków. Każde ze zdjęć jest opisane etykietą z odpowiadającą im nazwą ssaka. Model uczy się na podstawie tych obrazów, określając jakie charakterystyki opisują każde zwierzę. Gdy model dostanie nowe zdjęcie, będzie w stanie określić, czy to jeżyk, piesek, lub kotek.

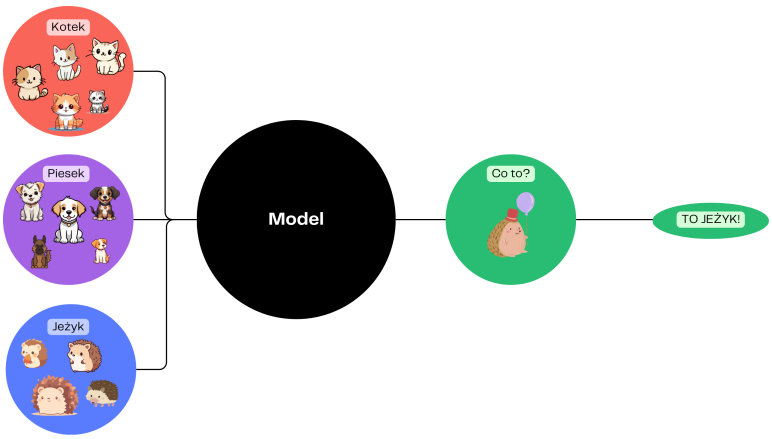

Rysunek 2.1: Przykład uczenia nadzorowanego.

2.2 Uczenie nienadzorowane

Uczenie nienadzorowane (ang. *unsupervised learning*) polega na analizie nieoznakowanych zbiorów danych bez przypisanych do tych tych danych etykiet. Ten rodzaj uczenia maszynowego jest stosowany w celu ekstrahowania cech generatywnych, wykrywania trendów, czy grupowania danych według podobieństw [34].

Przykład został zaprezentowany na Rys. 2.2. Widoczny jest zbiór zdjęć różnych zwierząt. Model analizując przekazane mu obrazy, może podzielić je na grupy o podobnych charakterystykach, na przykład na podstawie kształtu, obecności kolców, czy wąsów - choć model nie będzie w stanie określić, jak te grupy nazwać.

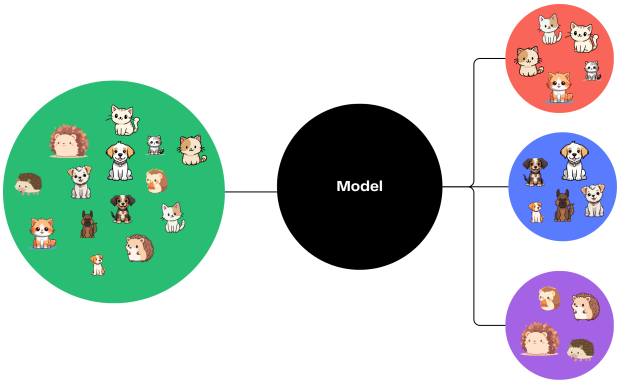

Rysunek 2.2: Przykład uczenia nienadzorowanego.

2.3 Uczenie przez wzmacnianie

Uczenie przez wzmacnianie (ang. *reinforcement learning*) polega na zastosowaniu agenta działającego w danym środowisku, który działa jak "ekspert". Podejmuje on decyzje, na podstawie których otrzymuje karę lub nagrodę. Nie wykorzystuje się tutaj etykiet, model uczy się poprzez doświadczenie uzyskane na podstawie interakcji ze środowiskiem, obserwacji i reagowaniu na wyniki [13].

Przykładem może być zobrazowane schematycznie na Rys. 2.3 wykorzystanie uczenia przez wzmacnianie do gry w szachy. Zaczynąc od losowych ruchów, model sukcesywnie uczy się strategii prowadzących do zwycięstwa, co w rezultacie sprawia, że model staje się coraz lepszym graczem.

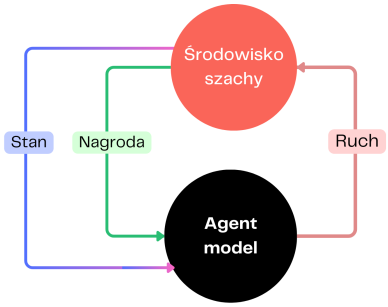

Rysunek 2.3: Przykład uczenia przez wzmacnianie.

2.4 Ewaluacja modeli

Macierz pomyłek

Macierz pomyłek (zaprezentowana jako Tabela 2.1) jest narzędziem służącym do podsumowywania wydajności klasyfikatora, bazując głównie na danych testowych, ale możliwe jest również sprawdzenie jak ta macierz wygląda dla danych treningowych, co w połączeniu z informacją o wynikach na zbiorze testowym daje wgląd na możliwe anomalie (np. przeuczenie (ang. *overlifting*)) w modelu. W jednym wymiarze macierz jest indeksowana przez prawdziwą klasę obiektu, a w drugim przez klasę przypisaną przez klasyfikator [42].

		Klasa rzeczywista	
		pozytywna	negatywna
Klasa predyktowana	pozytywna	prawdziwie pozytywna (TP)	fałszywie pozytywna (FP)
	negatywna	fałszywie negatywna (FN)	prawdziwie negatywna (TN)

Tabela 2.1: Macierz pomyłek.

Zgodnie z podaną macierzą pomyłek (Tabela 2.1) zaprezentowane zostały następujące oznaczenia jednostek w zależności od ich klasy rzeczywistej i przewidywanej [41]:

- Prawdziwie pozytywna (ang. *true positive, TP*): Przykłady prawidłowo zaklasyfikowane jako pozytywne.
- Prawdziwie negatywna (ang. *true negative, TN*): Przykłady prawidłowo zaklasyfikowane jako negatywne.
- Fałszywie pozytywna (ang. *false positive, FP*): Przykłady błędnie zaklasyfikowane jako pozytywne.
- Fałszywie negatywna (ang. *false negative, FN*): Przykłady błędnie zaklasyfikowane jako negatywne.

Dokładność

Dokładność (ang. *accuracy*) jest prostym i powszechnie stosowanym wskaźnikiem jakości całego modelu. Jest to odsetek przypadków prawidłowo sklasyfikowanych podzielony przez liczbę wszystkich przykładów [14].

$$\text{Dokładność} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FN} + \text{FP}}$$

Precyzja

Precyzja (ang. *precision*) jest wskaźnikiem oznaczającym proporcję sklasyfikowanych przypadków pozytywnych, które są faktycznie pozytywne [28].

$$\text{Precyzja} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Czułość

Czułość (ang. *recall*) to stosunek liczby poprawnie zaklasyfikowanych przykładów pozytywnych do liczby wszystkich rzeczywiście pozytywnych przykładów [14].

$$\text{Czułość} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Harmoniczna średnia precyzji i czułości

Harmoniczna średnia precyzji i czułości (ang. *F1-score*) równoważy miary precyzji i czułości, jednocześnie karząc ekstremalne wartości, którejś z nich. Jest użyteczna w przypadku niezbalansowanych zbiorów danych [29].

$$\text{Harmoniczna średnia precyzji i czułości} = \frac{2 \cdot \text{TP}}{2 \cdot \text{TP} + \text{FP} + \text{FN}}$$

Czas treningu

Czas treningu (ang. *training time*) to różnica między momentem zakończenia treningu modelu, a jego rozpoczęciem. Jest to pomocnicza metryka, zwłaszcza w sytuacjach, gdy trenowanie modeli jest kosztowne.

$$T_{\text{treningu}} = t_{\text{koniec treningu}} - t_{\text{start treningu}}$$

Rozdział 3

Modele

Ten rozdział został poświęcony ogólnym założeniom i charakterystyce modeli wykorzystanych w ramach uczenia maszynowego nadzorowanego, zastosowanych do klasyfikacji instrumentów.

W pracy, rozważane są następujące modele (zwane również klasyfikatorami): losowy model bazowy (podrozdział 3.1), regresja logistyczna (podrozdział 3.2), nawiny klasyfikator Bayesa (podrozdział 3.3), metoda K- najbliższych sąsiadów (podrozdział 3.4), drzewo decyzyjne i jego wzmocnienia (podrozdział 3.5), maszyna wektorów nośnych (podrozdział 3.6) oraz sieci neuronowe (podrozdział 3.7).

Dla ustalenia notacji zostały przyjęte oznaczenia jak w Tabeli 3.1 .

Symbol	**Opis**
$X = (X_1, \ldots, X_p)$	Wektor cech (zmienne objaśniające)
Y	Zmienna objaśniana
x	Realizacja wektora cech X (pojedyncza obserwacja)
y	Realizacja zmiennej objaśnianej Y
K	Liczba klas (unikalne wartości Y)
$y \in \{0, 1\}$	Klasy w przypadku klasyfikacji binarnej ($K = 2$)
$\mathbb{P}(Y = 1 \mid X = x)$	Prawdopodobieństwo przypisania obserwacji x do klasy 1

Tabela 3.1: Wykorzystywana notacja w problemie klasyfikacji.

3.1 Losowy model bazowy

Losowy model bazowy (ang. *Baseline random model*) jest prostym modelem wykorzystywanym w uczeniu maszynowym. Charakteryzuje się przewidywaniem wyników losowo, bez uprzedniej analizy danych i trenowania.

Niech h będzie zatem losowym modelem bazowym oraz $\tilde{X}$ oznacza liczbę przykładów, które zostały poprawnie sklasyfikowane. Przez losowość rozumiemy tutaj, że $\tilde{X}$ ma rozkład

B(n,p), gdzie n oznacza liczbę obserwacji, natomiast p jest prawdopodobieństwem sukcesu (poprawnej klasyfikacji obserwacji). Przykładowo: w problemie klasyfikacji binarnej przyjmujemy p=0.5, natomiast w przypadku, gdy mamy K=4 klasy, zakładamy, że p=0.25.

Wówczas, wartość oczekiwana dokładności klasyfikacji jest równa

$$\mathbb{E}\left(\frac{1}{n}\tilde{X}\right) = \frac{1}{n}\mathbb{E}(\tilde{X}) = \frac{1}{n} \cdot np = p$$

Oczekujemy zatem, że losowy model bazowy powinien poprawnie przyporządkowywać klasę w około $100p$ procentach przypadków. Jest to jednocześnie punkt odniesienia dla bardziej złożonych modeli, które powinny go przewyższać pod względem dokładności klasyfikacji.

3.2 Regresja logistyczna

Regresja logistyczna (ang. *logistic regression*) to powszechnie używany model uczenia nadzorowanego wykorzystywanego w zadaniach klasyfikacji binarnej. Model regresji logistycznej klasyfikuje obserwacje kierując się prawdopodobieństwem przynależności do danej klasy i wybierając klasę o największym prawdopodobieństwie. W szczególności, w klasyfikacji binarnej, mamy

$$\mathbb{P}(Y = 1 \mid X = x) = g(\vartheta^T x) = \frac{1}{1 + \exp\left(-\vartheta^T x\right)}, \tag{3.1}$$

gdzie:

$$\begin{aligned} x &= \text{pojedyncza obserwacja} \\ \vartheta &= \text{parametr modelu regresji logistycznej} \\ g &= \text{funkcja sigmoidalna} \end{aligned}$$

Jeśli prawdopodobieństwo (wzór 3.1) jest większe od 0.5, to obserwacja jest klasyfikowana jako 1, a w przeciwnym razie jako 0.

Funkcja straty regresji logistycznej (ang. *loss function*), zwana entropią krzyżową (ang. *cross-entropy loss*), wykorzystywana jest podczas treningu modelu w celu dokonywania lepszych predykcji [26]. Model dostosowuje swoje parametry, aby zminimalizować funkcję straty $\mathcal{L}(\vartheta)$, która wyraża się wzorem:

$$\mathcal{L}(\vartheta) = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right], \tag{3.2}$$

gdzie:

$$\begin{aligned} \hat{y}_i = g(\vartheta^T x_i) &= \text{wartość } i\text{-tego przykładu przewidywana przez model logistyczny} \\ \vartheta &= \text{parametr modelu regresji logistycznej} \\ x_i &= i\text{-ta obserwacja} \\ y_i &= \text{rzeczywista etykieta } i\text{-tej obserwacji} \\ n &= \text{liczba obserwacji w zbiorze danych} \end{aligned}$$

Do zadań klasyfikacji wieloklasowej, stosuje się metodę *One vs Rest*, znaną również jako *One vs All*, która poszerza możliwości regresji logistycznej o zadania z więcej niż dwiema klasami. Polega ona na tworzeniu klasyfikatora binarnego dla każdej unikalnej klasy, odróżniającej się od zbioru pozostałych. Ostateczne prawdopodobieństwo przynależności do danej klasy przypisuje się na podstawie normalizacji prawodpodobieństw wszystkich klasyfikatorów [5].

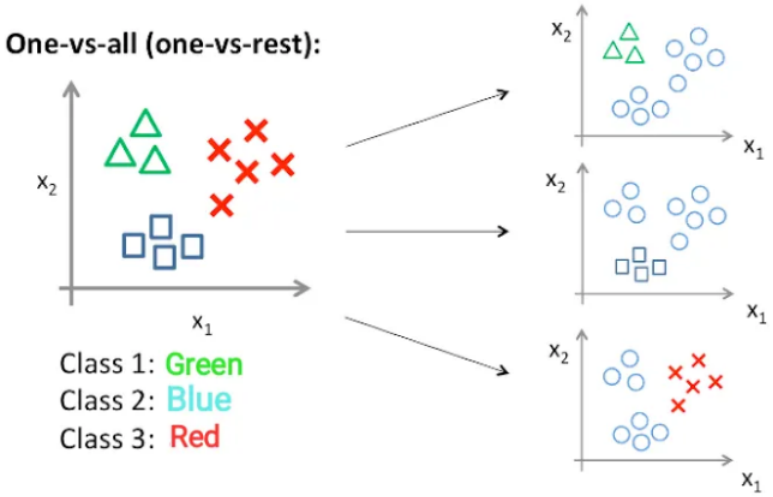

Rysunek 3.1: Przykładowa klasyfikacja OvR: Źródło [35].

Przykład został zaprezentowany na Rysunku 3.1, stworzone zostały 3 osobne klasyfikatory, gdzie sprawdzana jest przynależność obiektu do klasy na podstawie uproszczonego schematu: [△] lub [×, □], [×] lub [△, □], [□] lub [△, ×].

Aby uniknąć problemów z przeuczeniem i przechwytywaniem szumów przez model, sprawdzono również różne metody regularyzacji regresji logistycznej, aby zmniejszyć wielowymiarowość i zwiększyć dokładność klasyfikacji [1].

W przypadku regularyzacji zamiast minimalizować wartości $\mathcal{L}(\vartheta)$ (wzór 3.2), rozpatrujemy problem minimalizacji wyrażenia $\mathcal{L}(\vartheta) + c(\vartheta)$, gdzie $c(\vartheta)$ jest jednym z członów regularyzacyjnych podanych w Tabeli 3.2.

Metoda	**Człon regularyzacyjny**
Lasso	$\lambda \sum_{j=1}^{p} \lvert\vartheta_j\rvert$
Ridge	$\lambda \sum_{j=1}^{p} \vartheta_j^2$
Elastic Net	$\lambda_1 \sum_{j=1}^{p} \lvert\vartheta_j\rvert + \lambda_2 \sum_{j=1}^{p} \vartheta_j^2$

Tabela 3.2: Wybrane metody regularyzacji: Źródło [17].

Przy Tabeli 3.2 zostały przyjęte następujące oznaczenia:

λ = hiperparametr regularyzacji kontrolujący wielkość kary
λ_1 = hiperparametr odpowiadający za wkład metody Lasso w siłę regularyzacji
λ_2 = hiperparametr odpowiadający za wkład metody Ridge w siłę regularyzacji
ϑ_j = parametr odpowiadający wpływowi j-tej cechy na wynik

Regularyzacja Lasso (ang. *Lasso regression*) w modelu odpowiada za sprowadzenie współczynników nieistotnych zmiennych do zera. Ostatecznie tylko kluczowe zmienne znajdują miejsce w modelu. Regularyzacja grzebietowa (ang. *Ridge regression*) zachowuje wszystkie zmienne w ostatecznym modelu, ale te mniej znaczące mają współczynniki bliskie zeru. Regularyzacja sieci elastycznej (ang. *Elasticnet regression*) łączy ze sobą regularyzację Lasso i grzebietową - zmniejsza niektóre współczynniki by były bliskie zeru, jak i niektórym współczynnikom przypisuje dokładnie zero [38].

3.3 Naiwny klasyfikator Bayesa

Naiwny klasyfikator Bayesa (ang. *naive Bayes classifier*) jest metodą używaną w uczeniu nadzorowanym, zakładającą niezależność cech w każdej klasie. Pomimo niedoskonałości założenia o niezależności cech w każdej klasie, w praktyce ten model jest w stanie dorównywać bardziej złożonym i skomplikowanym modelom [33]. Reguła Bayesa przy swoich założeniach o niezależności wygląda następująco [43]:

$$\mathbb{P}(Y = k \mid X) = \frac{\mathbb{P}(Y = k) \prod_i \mathbb{P}(X_i \mid Y = k)^{w_i}}{\sum_{j=1}^{K} \left(\mathbb{P}(Y = j) \prod_i \mathbb{P}(X_i \mid Y = j)^{w_i}\right)},$$

gdzie $w_i \in [0, 1]$ jest wagą przypisaną dla i-tej zmiennej.

Czasem to naiwne założenie o warunkowej niezależnosci zmiennych pogarsza działanie modelu. Aby uniknąć tego problemu zostały zaprojektowane metody selektywnego wyboru zmiennych. Polegają na dodawaniu i usuwaniu zmiennych, aby dopasować najlepszy podzbiór danych. Możliwe jest zastosowanie jednego modelu z odpowiednio przypisanymi wagami do zmiennych, zamiast uśredniania wielu selektywnych klasyfikatorów.

Wielomianowy Naiwny Klasyfikator Bayesa (ang. *multinomial Naive Bayes*) zakłada, że cechy zmiennych pochodzą z rozkładu wielomianowego, który opisuje prawdopodobieństwo liczności z kilku kategorii. Jest skuteczny, gdy cechy są dyskretne, a nie ciągłe. Gaussowski Naiwny Klasyfikator Bayesa (ang. *Gaussian Naive Bayes*) zakłada, że wartości cech są niezależne od siebie oraz przyjmuje się, że każda ciągła cecha ma odpowiedni rozkład normalny. Ostatni wykorzystywany wariant naiwnego klasyfikatora Bayesa (tj. Bernoulliego, ang. *Bernoulli Naive Bayes*) zakłada, że dane są dyskretne, a odpowiedni rozkład jest rozkładem typu Bernoulliego [16].

Klasyfikator	**Wzór**
Multinomial	$\mathbb{P}(Y \mid X) = \mathbb{P}(Y) \prod_{i=1}^{n} \mathbb{P}(X_i \mid Y)$
Gaussian	$\mathbb{P}(X \mid Y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(X_i-\mu)^2}{2\sigma^2}\right)$
Bernoulli	$\mathbb{P}(X \mid Y) = \mathbb{P}(X_i \mid Y)^{X_i} \cdot (1 - \mathbb{P}(X_i \mid Y))^{1-X_i}$

Tabela 3.3: Wybrane klasyfikatory wariantów Naiwnego Bayesa.

Wzory opisujące wymienione warianty naiwnego klasyfikatora Bayesa są podane w Tabeli 3.3, przy czym zostały przyjęte następujące oznaczenia:

$$\begin{aligned}
Y &= \text{przewidywana klasa obiektu } i \\
X_i &= i\text{-ta cecha obiektu} \\
\mu &= \text{wartość oczekiwana cechy } X_i \\
\sigma^2 &= \text{wariancja cechy } X_i \\
p &= \text{liczba cech}
\end{aligned}$$

3.4 Metoda K - najbliższych sąsiadów

Metoda K - najbliższych sąsiadów (ang. *K - nearest neighbour classification, KNN*) to prosta metoda stosowana w problemach klasyfikacji - obiekty są klasyfikowane na podstawie klasy ich najbliższych sąsiadów. Wynik określa się na podstawie głosu większości [18]. Ta metoda może dawać inne wyniki w zależności od wybranej metryki, liczby sąsiadów, czy wybranych wag.

W pracy wykorzystano dwie metryki w celu wyodrębnienia najlepszego modelu KNN:

- **metryka Manhattan** (metryka miejska, taksówkowa) sumująca bezwględne różnice wartości wzdłuż każdej osi:

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^{n} |x_i - y_i|, \quad x, y \in \mathbb{R}^n,$$

- **metryka Euklidesowa** mierząca najkrótszą odległość w przestrzeni:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}, \quad x, y \in \mathbb{R}^n.$$

Skorzystano również z metody ważonych sąsiadów (ang. *weighted neighbours*) i jednostkowych sąsiadów (ang. *uniform neighbours*). Jednostkowi sąsiedzi mają taką samą wagę niezależnie jak daleko znajdują się od klasyfikowanego obiektu. W przypadku ważonych sąsiadów dobiera się odpowiednią wagę sąsiadującym obiektom - im obiekt jest bliżej, tym większą wagę ma w przypadku doboru klasy.

Rysunek 3.2 jest przykładem ukazującym możliwości klasyfikacji w zależności od różnych czynników. Gdy wybierze się klasyfikację na podstawie liczby sąsiadów i ich jednostkową wagę, to w przypadku wyboru trzech najbliższych, obiekt (●) zostanie sklasyfikowany

jako czerwony trójkąt, ale jak ta liczba zmieni się do 5 - to wtedy zostanie niebieskim kwadratem. Jednakże w przypadku sąsiadów ważonych, obiekt będzie sklasyfikowany jako czerwony trójkąt zarówno przy 3, jak i 5 sąsiadach.

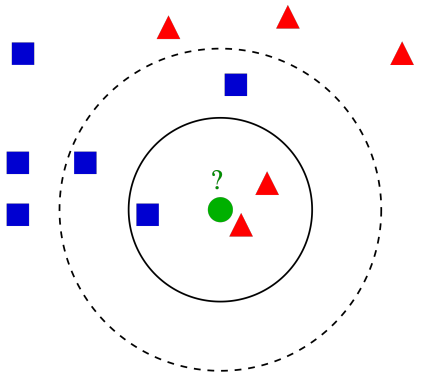

Rysunek 3.2: Przykładowy schemat klasyfikacji w KNN: Źródło [45].

3.5 Drzewo decyzyjne i jego wzmocnienia

Drzewo decyzyjne (ang. *Decision tree*) jest to metoda podobna do procesu myślowego człowieka związanego z podejmowaniem decyzji, dzięki czemu jest intuicyjne. Drzewo decyzyjne składa się z: korzenia, węzłów wewnętrznych i liści, pokazanych na Rysunku 3.3. Korzeń jest podstawą, rodzicem każdego węzła. W węźle sprawdzany jest warunek sformułowany w terminach wielkości danego atrybuty (danej cechy) np. sprawdzamy czy cecha 1 jest większa od 10. Uzyskany wynik decyduje o wyborze gałęzi, po które dalej będziemy sie poruszać w dół drzewa. W przypadku spełnienia warunku wybieramy gałąź po prawej (jak np. w Rysunku 3.4), a w przypadku niespełnienia tego warunku wybieramy gałąź po lewej. Ostateczna etykieta przypisywana jest w liściach [15].

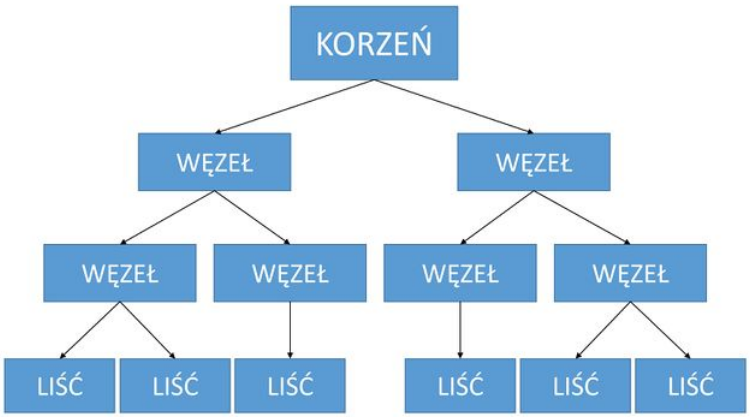

Rysunek 3.3: Schemat blokowy drzewa decyzyjnego [24].

Przykład prostej klasyfikacji został zaprezentowany na Rysunku 3.4. Celem jest przewidywanie, czy dany kandydat dostanie pracę na podstawie kilku wybranych cech. Jeśli kandydat ma poniżej 3 lat doświadczenia w branży, to niestety pracy dla niego nie będzie, ale jeśli kandydat ma np. 4 lata doświadczenia, więcej niż 2 kierunki ukończone, oraz zaprezentował się powyżej 6 w skali wybranej przez rekruterów, to praca na niego czeka. Działa to na zasadzie "Jeśli kandydat ma... to ...".

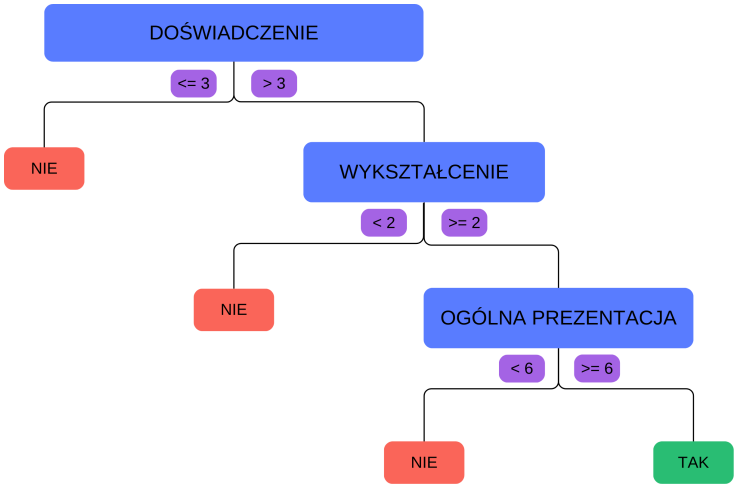

Rysunek 3.4: Przykład drzewa decyzyjnego: Źródło [44].

Do pomiaru czystości lub jednorodności w zbiorze danych służy zysk informacji. Obrazuje on sposób rozkładania się danych w kontekście zmiennej odpowiedzi. Wyższa wartość entropii wskazuje na większą ilość zawartych informacji. Zysk informacyjny dzieli zbiór na podstawie atrybutów, który skutkuje najmniejszą entropią [15].

$$\text{Entropia} = -\sum_{i=1}^{K} p_i \log p_i,$$

gdzie p_i oznacza prawdopodobieństwo wystąpienia i-tej klasy.

Alternatywną opcją jest również wskaźnik Giniego - miara zanieczyszczenia zbioru danych. Jest to kryterium mierzące rozbieżność między rozkładami prawdopopodobieństwa wartości finalnego atrybutu (ostatecznie wybrany atrybut do podziału węzła w drzewie decyzyjnym na podstawie kryterium czystości zbioru danych). Jak w przypadku entropii algorytm dąży do minimalizacji wskaźnika Giniego [40].

$$\text{Gini} = 1 - \sum_{i=1}^{K} p_i^2$$

3.5.1 Wzmocnienia

Wzmocnienia (ang. *Ensemble learning*) polegają na łączeniu wielu modeli w celu zwiększenia ich skuteczności. Kilka mniej wydajnych modeli połączonych ze sobą prowadzi do lepszych wyników niż użycie tylko jednego - to główny zamysł używania wzmocnień. Do drzew decyzyjnych zastosowano trzy wzmocnienia: las losowy, bagging i boosting.

Bagging i las losowy

Bagging (skrót od ang. *Bootstrap aggregating*) i las losowy (ang. *random forest*) są to klasyfikatory składające się ze zbioru drzew decyzyjnych, opartym na podejściu grupowym - każde z drzew oddaje jeden głos, przypisując etykietę każdej danej wejściowej, a ostateczny wynik jest uzyskiwany przez głosowanie większościowe [8].

Las losowy charakteryzuje się tym, że dla każdego drzewa wybiera się losowo, ze zwracaniem, podzbiór danych wejściowych z pierwotnego zbioru danych (ang. *bootstrap sampling*) jak i również każde drzewo jest budowane z węzłów, w których model losowo wybiera podzbiór cech, które zostaną uwzględnione przy decydowaniu o podziale węzła [2].

Bagging, również losowo, ze zwracaniem, tworzy podzbiory danych treningowych, z tą różnicą, że w tej metodzie model nie wybiera podzbiorów atrybutów, tylko korzysta z całego ich zbioru [27].

Boosting

Boosting to metoda różniąca się od Baggingu i lasu losowego. Polega ona na tworzeniu sekwencyjnym tworzeniu serii klasyfikatorów, składający się ze stopniowego procesu udoskonalania klasyfikatora. W boostingu drzewa decyzyjne są dopasowywane iteracyjnie do danych treningowych, akcentując próbki, które zostały źle sklasyfikowane przez istniejący zbiór drzew [12].

Algorytm przypisuje wagi każdemu pojedynczemu klasyfikatorowi. Im większa waga, tym większy ma to wpływ na końcowe głosowanie odnośnie wyboru klasy. Wagi dostosowuje się w zależności od wydajności klasyfikatora - zazwyczaj początkowe klasyfikatory mają najmniejszą wagę, zważywszy na fakt, że mają mniej informacji odnośnie błędnie sklasyfikowanych obiektów [27].

3.6 Maszyna wektorów nośnych

Maszyna wektorów nośnych (ang. *Support vector machines, SVM*) jest to relatywnie młoda (wspominana przez Vapnika w 1979 i opublikowana w artykule z 1995 tego autora [6]) metoda uczenia maszynowego w klasyfikacji binarnej. Jej idea polega na znalezieniu hiperpłaszczyzny, która odpowiednio oddziela dane w przestrzeni p - wymiarowej na dwie klasy (w przypadku klasyfikacji binarnej). Dane w wielu przypadkach nie są liniowe, a więc SVM wprowadził pojęcie "przestrzeni cech indukowanej jądrem", w której to przekształca dane w przestrzeń o większej liczbie wymiarów, gdzie dzięki temu, dane stają się możliwe do rozdzielenia [6]. Więcej informacji na temat metody SVM można znaleźć m.in. [19], [11] oraz [30].

SVM wybiera hiperpłaszczyznę z największym marginesem, aby móc doprowadzić do maksymalnego oddzielenia między tymi dwiema klasami. Margines to suma najkrótszych odległości od hiperpłaszczyzny podziału do najbliższych punktów danych z obu klas. Zostaje przeprowadzone mapowanie z przestrzeni wejściowej do przestrzeni cech w celu uniknięcia problemów nieliniowej klasyfikacji.

W tym celu wykorzystuje się tzw. *kernel trick*, który ułatwia obliczenia w wielowymiarowej przestrzeni cech tj. umożliwia ominięcie obliczania poszczególnych współrzędnych. W pracy wykorzystane zostały następujące jądra:

- Liniowe: $K(\mathbf{x}_i, \mathbf{x}) = \mathbf{x}_i^T \mathbf{x}$,
- RBF: $K(\mathbf{x}_i, \mathbf{x}) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}\|^2}{2\sigma^2}\right)$.

Dzięki temu klasyfikacja liniowa w nowej przestrzeni jest równoważna klasyfikacji nieliniowej w pierwotnej przestrzeni. Ponadto w rozważanych modelach uwzględniany będzie współczynnik C opisujący wielkość kary za błędną klasyfikację. Klasyfikacja wieloklasowa jest możliwa, poprzez łączenie wielu klasyfikatorów binarnych za pomocą metody sprężenia parami (ang. *pairwise coupling method*) [46].

Przykład klasyfikacji z wykorzystaniem metody maszyny wektorów nośnych jest przedstawiony na Rysunku 3.5. Widoczne są dwa zbiory danych należące do różnych klas. Linie przerywane reprezentują marginesy, które wyznaczają odległość od hiperpłaszczyzny rozdzielającej (linia ciągła). Na rysunku wyróżniono trzy przypadki:

- obserwacja (a) - poprawnie sklasyfikowana, znajdująca się po "właściwej" stronie marginesu,
- obserwacja (b) - poprawnie sklasyfikowana, ale leżąca na marginesie,
- obserwacja (c) - znajduje się po "złej" stronie marginesu i jest sklasyfikowana błędnie.

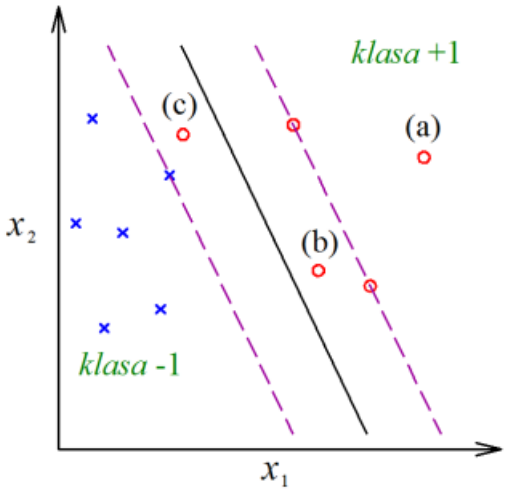

Rysunek 3.5: Przykład klasyfikacji obiektów w SVM [11].

3.7 Sieci neuronowe

Sieci neuronowe (ang. *Neural network, NN*) to model inspirowany badaniami nad sposobem działania biologicznych układów nerwowych. Cechami charakterystycznymi sieci jest umiejętność uczenia się złożonych nieliniowych zależności między wejściem, a wyjściem, wykorzystania metod treningowych i adaptowania się do danych [3].
Standardowa struktura sieci neuronowych składa się z szeregu elementów przetwarzających (ang. *processing elements, PE*) lub węzłów, ułożonych warstwami: warstwa wejściowa, warstwa lub warstwy ukryte i warstwa wyjściowa [36].

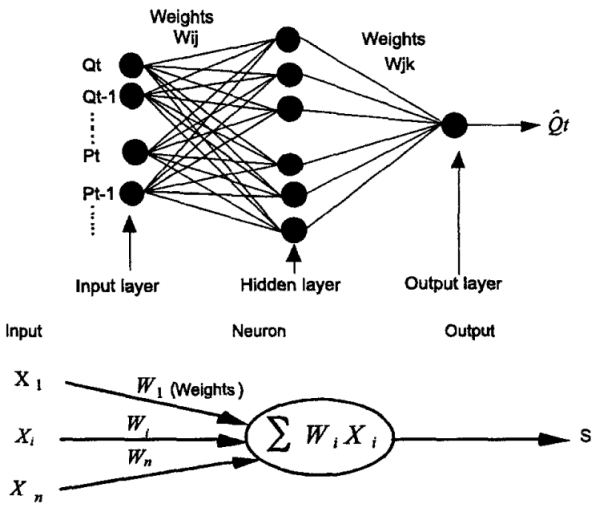

Rysunek 3.6: Schemat sieci neuronowej [32].

Struktura NN została zaprezentowana na Rysunku 3.6. Każdy węzeł j odbiera sygnały pochodzące z każdego węzła i będącego w warstwie poprzedniej. Każdemu sygnałowi wejściowemu (X_i) przypisywana jest waga (W_{ij}). Efektywny sygnał przychodzący (S_i) przychodzący do węzła j jest sumą ważoną wszystkich sygnałów wejściowych, a b_j to wartość progowa tego neuronu [32].

$$S_j = \sum_{i=1}^{n} X_i W_{ij} + b_j$$

Efektywny sygnał przychodzący S_j przechodzi przez nieliniową funkcję aktywacji, aby stworzyć sygnał wyjściowy y_i węzła [32].

W pracy skorzystano z dwóch funkcji aktywacji [31]:

- tangensa hiperbolicznego (ang. *the hyperbolic tan function*):

$$\tanh(x) = \frac{2}{1 + e^{-2x}} - 1$$

- jednostki liniowej zrektyfikowanej (ang. *the rectified linear unit function*):

$$\mathrm{ReLU}(x) = \max(0, x)$$

W przypadku uczenia nadzorowanego sieć przetwarza dane wejściowe, przechodząc przez wszystkie warstwy w procesie propagacji w przód (ang. forward pass). Następnie otrzymane przewidywania porównywane są z rzeczywistymi etykietami. W tym celu wykorzystywana jest odpowiednia funkcja straty np. w przypadku problemu klasyfikacji jest nią *categorical cross-entropy*. Błędy popełnione przez model są propagowane z powrotem, co sprawia, że model dostosowuje wagi kontrolujące sieć. Proces ten nosi nazwę propagacji wstecz (ang. *back propagation*). Ten mechanizm powtarza się wielokrotnie w tzw. epokach, gdyż poprawiane są stale wagi, by udoskonalić sieć neuronową [22].

Rozdział 4

Przetwarzanie i analiza danych

4.1 Zbiór danych i ich przetwarzanie

Rozważany zbiór danych to *Musical Instrument's Sound Dataset* [25] i pochodzi ze strony *Kaggle*. Zbiór zawiera pliki audio dla 4 rodzajów instrumentów: gitary, bębna, skrzypiec i fortepianu. Rys. 4.1 ilustruje liczebność przykładów dźwiękowych dla poszczególnych instrumentów.
W zbiorze testowym jest po 20 plików audio dla każdego instrumentu, natomiast widoczne jest niezbalansowanie w zbiorze treningowym. Klasa fortepianu zawiera 528 przykładów, a w klasach pozostałych instrumentów jest ich 700. Łącznie daje to 2708 plików audio.

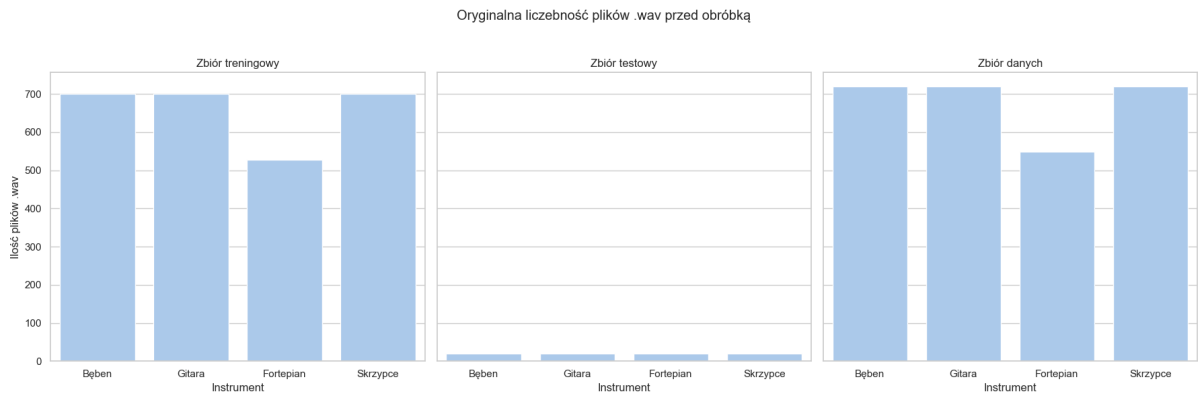

Rysunek 4.1: Oryginalna liczebność plików .wav przed obróbką

Aby móc skutecznie i efektywnie zastosować algorytmy uczenia maszynowego, przeprowadzono obróbkę danych, która miała na celu poprawę jakości zbiorów oraz ich zbalansowanie.

Oryginalny zbiór danych zawiera pliki audio o różnej długości- od plików 2 minutowych, po pliki zaledwie sekundowe. Średnia długości nagrań w zbiorze treningowym to 20 sekund, w testowym - 24 sekund. Nierównomierna długość nagrań mogłaby negatywnie wpływać na proces uczenia modeli. Dlatego też, wszystkie zostały sprowadzone do 1-sekundowych przykładów poprzez segmentację. Pliki zawierające ciszę, jak i przykłady poniżej 1 sekundy zostały usunięte ze zbiorów.

Ostatnim etapem było zbalansowanie zbioru treningowego i testowego. Równowaga w liczebności plików pomogła uniknąć problemów z niezbalansowantm rozkładem klas, który mógłby prowadzić do nadmiernego dopasowania modeli do klas dominujących, co obniżyłoby dokładność przy klasach z mniejszą ilością przykładów.

Aby zbalansować zbiory zsumowano przykłady dźwiękowe poszczególnych instrumentów i wyrównano ich liczebność względem instrumentu z najmniejszą ich liczbą - bębna, z ilością plików wynoszącą 8300. Podzielono poszczególne zbiory instrumentów na zbiór treningowy (6640 plików) i testowy (1640). Końcową liczebność plików przedstawiono na Rys. 4.2. Ilustruje on wyniki zastosowanych procedur przetwarzania - po 8300 plików audio dla każdego instrumentu podzielone w proporcjach 80 : 20, co daje łącznie 33200 przykładów.

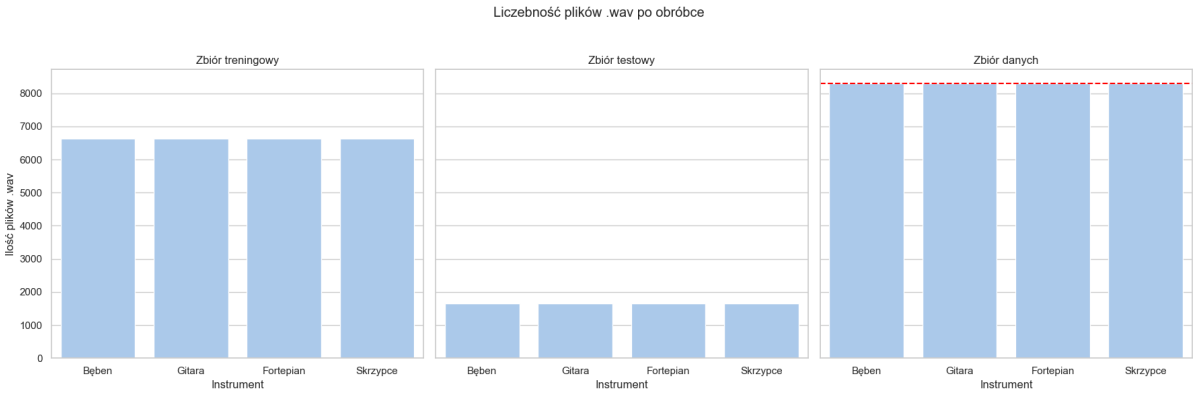

Rysunek 4.2: Liczebność plików .wav po obróbce

4.2 Ekstrakcja współczynników MFCC

Jako dane wejściowe do modeli uczenia maszynowego użyto 13 współczynników capstralnych Mel (MFCC) wyodrębnionych dla wszystkich rodzajów instrumentów użytych w analizie. Współczynniki wyodrębniono z wykorzystaniem biblioteki Librosa w języku programowania Python.

Współczynniki capstralne Mel to zestaw cech ekstrahowanych z sygnału dźwiękowego, które reprezentują aspekty kształtu widmowego sygnału. Są powszechnie stosowane w systemach rozpoznawania mowy i również coraz cześciej znajdują zastosowanie w dziedzinie przetwarzania dźwięków. Jedną z zalet MFCC jest to, że bardzo dobrze naśladują sposób, w jaki ludzkie ucho odbiera dźwięki, dzięki temu, że są pozycjonowane logarytmicznie. Jednak mają problemy z obecnością szumów addytywnych [21].

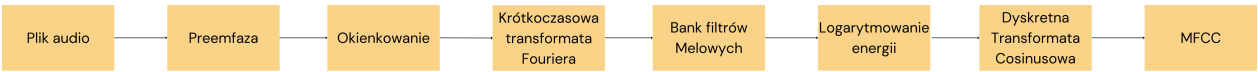

Rysunek 4.3: Diagram etapów ekstrakcji współczynników MFCC

Podstawowy koncept ekstrakcji cech MFCC przedstawiono na Rysunku 4.3. Dokładniejszy opis tej sekwencji, opracowano na podstawie informacji zamieszczonych w przytoczonych artykułach [9], [10].

Mianowicie, poszczególne etapy ekstrakcji cech MFCC można scharakteryzować następująco:

- **Preemfaza** - przepuszczanie próbki dźwiękowej przez filtr, który podkreśla wyższe częstotliwości. Dzięki temu zwiększona jest energia sygnału przy wyższych częstotliwościach.
- **Ramkowanie** - sygnał dźwiękowy jest dzielony na fragmenty o długości 20-30 ms. Dźwięki są sygnałem, który zmienia się w czasie, a więc ramkowanie jest ważne, badając dźwięk w krótkim okresie czasu, właściwości dźwięku są w miarę stacjonarne.
- **Okienkowanie** - powstałe klatki mnożone są przez okno Hanninga, aby zachować ciągłość sygnału i uniknąć zjawiska przecieku spektralnego.
- **Krótkoczasowa transformata Fouriera (STFT)** - na każdym oknie wykonuje się krótkoczasową transformatę Fouriera, by móc przejść z domeny czasowej do częstotliwościowej.
- **Bank filtrów Mel** - charakterystyka częstotliwościowa jest mnożona przez zestaw filtrów pasmowych trójkątnych, by pozyskać gładkie widmo wielkości.
- **Logarytmowanie energii** - obliczany jest logarytm energii z banków filtrów, by dynamika różnic między wartościami została zwiększona.
- **Dyskretna transformacja kosinusowa (DCT)** - Ostatnim krokiem jest użycie dyskretnej transformacji kosinusowej, aby przekształcić logarytmowane wartości w zestaw współczynników MFCC.

4.3 Analiza zbioru danych

Wzory i definicje statystyczne

W pracy użyto następujących wzorów statystycznych i na ich podstawie przeprowadzono analizę wyodrębionych współczynników capstralnych Mel dla wybranych instrumentów [7].

- **Mediana**: Wartość dzieląca uporządkowany zbiór danych na dwie równe części, gdzie połowa wartości jest mniejsza lub równa medianie, a druga połowa jest większa lub równa medianie.
- **Kwartyle**: Miary pozycyjne, dzielące uporządkowany zbiór danych na części. Pewne szczególne kwantyle: rzędu $0,25$ (Q_1 - pierwszy kwartyl), rzędu 0.50 (Q_2 - mediana) oraz rzędu 0,75 (Q_3 - trzeci kwartyl) tj. liczby Q_k spełniające warunek

$$F(Q_k) = 0.25 \cdot k, \quad \text{gdzie} \quad k = 1, 2, 3 \quad \text{oraz } F \text{ jest dystrybuantą rozkładu.}$$

- **Minimum**: Najmniejsza wartość w zbiorze danych.
- **Maksimum**: Największa wartość w zbiorze danych.

- **Rozstęp międzykwartylowy**: Miara zmienności danych, wyznaczana jako różnica między trzecim a pierwszym kwartylem.

$$IRQ = Q_3 - Q_1$$

- **Rozstęp**: Miara zmienności danych, jest to różnica między największą i najmniejszą wartością w zbiorze danych.

$$R = x_{\max} - x_{\min}$$

- **Średnia arytmetyczna**: Średnia wartość w zbiorze danych, suma wszystkich wartości podzielona przez liczbę tych wartości.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

- **Wariancja**: Suma kwadratów odchylenia od średniej podzielonych przez $n-1$, gdzie n jest liczbą wartości w danych.

$$\sigma^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

- **Odchylenie standardowe**: Pierwiastek kwadratowy z wariancji.

$$\sigma = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

- **Współczynnik zmienności**: Miara względnej zmienności, stosunek odchylenia standardowego do średniej arytmetycznej.

$$CV = \frac{\sigma}{\bar{x}}$$

- **Kurtoza**: Względna miara koncentracji i spłaszczenia rozkładu, określająca rozmieszczenie i koncentrację wartości w pobliżu średniej.

$$K = \frac{m_4}{\sigma^4} - 3,$$

gdzie: m_4 - moment centralny rzędu czwartego, σ^2 - wariancja.

- **Współczynnik skośności**: Miara asymetrii rozkładu prawdopodobieństwa, wskazująca na to, w którą stronę rozkład jest asymetryczny i jak bardzo.

$$AQ = \frac{Q_1 + Q_3 - 2m}{Q_3 - Q_1},$$

gdzie: m — mediana, Q_1 - pierwszy kwartyl, Q_3 - trzeci kwartyl.

Prezentacja danych

W tej części zaprezentowane zostały statystyki opisowe jak i wykresy pudełkowe określające cały zbiór danych. Wartości statystyk w Tabelach 4.1 oraz 4.2 zostały zaokrąglone do dwóch miejsc po przecinku.

Statystyki te pozwalają na indetyfikację podstawowych trendów, potencjalnych podobieństw między instrumentami jak i możliwych anomalii.

	$MFFC_i$	**Odchylenie standardowe**	**Wariancja**	**Kurtoza**	**Współczynnik skośności**	**Współczynnik zmienności**	**Średnia arytmetyczna**
Bęben	**0**	193,02	37256,83	-0,62	-0,31	-0,49	-394,01
	1	45,67	2085,69	1,22	0,65	0,77	59,66
	2	21,69	470,40	2,50	-0,33	1,40	15,50
	3	15,47	239,41	0,54	-0,11	0,66	23,54
	4	15,65	244,81	-0,06	0,24	2,31	6,76
	5	11,45	131,00	0,17	-0,34	0,92	12,45
	6	11,43	130,55	-0,26	-0,09	4,97	2,30
	7	9,49	89,97	-0,29	-0,13	1,77	5,37
	8	9,65	93,03	-0,38	0,03	12,90	0,75
	9	8,64	74,59	-0,69	-0,07	2,74	3,15
	10	7,82	61,09	-0,10	-0,09	-26,05	-0,30
	11	7,04	49,53	0,06	-0,16	3,06	2,30
	12	7,41	54,97	-0,13	-0,19	-3,98	-1,86
Gitara	**0**	153,02	23414,31	-0,51	-0,27	-0,34	-447,91
	1	52,30	2735,44	-0,65	-0,26	0,37	143,19
	2	28,57	816,42	1,70	-0,37	2,05	13,96
	3	20,70	428,58	0,43	-0,24	1,22	17,00
	4	13,95	194,55	1,69	-0,56	3,45	4,05
	5	10,88	118,48	0,56	-0,46	15,86	0,69
	6	9,37	87,73	0,57	-0,22	-2,77	-3,38
	7	8,98	80,68	0,30	-0,18	-1,98	-4,53
	8	9,62	92,46	0,36	-0,36	-1,54	-6,26
	9	8,68	75,29	1,06	-0,33	-1,73	-5,02
	10	8,92	79,55	1,40	0,02	-1,52	-5,88
	11	8,45	71,41	2,51	0,17	-1,67	-5,06
	12	8,77	76,84	3,57	0,14	-1,49	-5,89
Fortepian	**0**	83,91	7041,57	2,71	-0,96	-0,23	-358,89
	1	37,71	1422,42	6,67	-1,53	0,19	196,12
	2	32,84	1078,62	1,01	-0,22	2,67	12,30
	3	16,98	288,16	3,52	0,81	-4,57	-3,71
	4	13,77	189,72	0,61	-0,21	12,05	1,14
	5	13,08	171,14	0,33	0,08	-2,08	-6,29
	6	10,46	109,36	0,81	0,12	-1,13	-9,22
	7	10,46	109,32	0,94	0,21	-1,16	-9,00
	8	10,04	100,88	0,88	0,19	-1,08	-9,29
	9	10,57	111,67	0,99	0,28	-1,79	-5,89
	10	10,93	119,51	0,37	0,28	-1,79	-6,12
	11	11,17	124,73	0,39	0,29	-2,63	-4,24
	12	10,27	105,50	0,24	0,03	-3,07	-3,35
Skrzypce	**0**	115,11	13250,29	0,94	-1,08	-0,34	-343,22
	1	34,37	1181,55	-0,14	-0,12	0,44	77,64
	2	17,48	305,62	1,03	0,31	-0,36	-48,37
	3	17,04	290,48	-0,40	0,46	1,21	14,09
	4	13,26	175,84	-0,29	-0,10	-0,72	-18,37
	5	14,34	205,52	-0,53	0,08	-0,59	-24,12
	6	10,61	112,52	1,14	0,43	-0,57	-18,48
	7	11,08	122,68	1,14	0,73	-1,54	-7,18
	8	12,81	164,08	0,51	0,62	-1,17	-10,94
	9	13,26	175,95	0,19	0,62	-2,54	-5,23
	10	13,07	170,83	0,18	0,48	-1,08	-12,12
	11	13,29	176,60	0,30	0,10	6,61	2,01
	12	13,56	183,77	0,12	0,20	-4,97	-2,73

Tabela 4.1: Wybrane statystyki dla 13 współczynników capstralnych Mel dla klasyfikowanych instrumentów.

	$MFFC_i$	**Kwartyl rzędu 1/4**	**Mediana**	**Kwartyl rzędu 3/4**	**Rozstęp międzykwartylowy**	**Minimum**	**Maksimum**	**Rozstęp**
Bęben	**0**	-541,02	-373,69	-238,61	302,41	-1044,32	35,58	1079,90
	1	30,22	53,38	81,80	51,58	-181,26	253,31	434,57
	2	2,64	15,91	27,43	24,78	-115,39	102,43	217,82
	3	13,04	23,62	34,30	21,26	-45,56	85,05	130,61
	4	-4,48	5,64	16,53	21,01	-52,92	60,35	113,27
	5	4,18	12,93	21,16	16,98	-36,70	43,89	80,58
	6	-6,00	1,99	11,07	17,07	-47,99	33,75	81,74
	7	-1,78	5,45	12,76	14,54	-41,76	34,91	76,67
	8	-6,32	0,37	7,49	13,81	-40,51	25,37	65,88
	9	-3,38	3,33	10,13	13,51	-31,67	44,24	75,91
	10	-5,86	-0,44	5,39	11,25	-37,00	28,01	65,01
	11	-2,81	3,11	7,42	10,24	-28,67	34,67	63,34
	12	-7,06	-1,61	3,75	10,81	-29,87	28,09	57,96
Gitara	**0**	-556,16	-435,66	-335,11	221,05	-931,84	-61,03	870,81
	1	104,34	149,43	183,36	79,02	5,12	289,63	284,51
	2	-0,35	15,36	30,63	30,98	-108,22	132,50	240,72
	3	5,02	18,27	31,54	26,52	-51,38	96,30	147,68
	4	-3,44	5,01	12,32	15,75	-69,34	54,06	123,40
	5	-5,87	1,74	8,35	14,22	-43,77	44,14	87,90
	6	-9,52	-3,09	3,11	12,63	-47,92	37,27	85,20
	7	-10,23	-4,15	1,57	11,80	-38,00	34,12	72,12
	8	-12,38	-5,67	0,59	12,97	-44,69	30,38	75,07
	9	-10,21	-4,40	0,91	11,12	-47,20	45,42	92,62
	10	-11,43	-5,41	-0,04	11,39	-42,41	47,42	89,84
	11	-10,16	-4,72	0,37	10,52	-38,86	50,39	89,25
	12	-10,96	-5,40	-0,30	10,67	-54,47	58,88	113,35
Fortepian	**0**	-399,43	-350,74	-305,14	94,29	-860,67	-53,27	807,40
	1	176,73	203,19	221,92	45,19	-211,85	292,61	504,47
	2	-7,87	12,96	33,21	41,08	-213,09	140,91	353,99
	3	-14,87	-5,97	5,15	20,02	-118,76	134,97	253,73
	4	-7,91	1,48	10,78	18,69	-66,34	74,32	140,65
	5	-15,03	-6,02	2,53	17,56	-48,60	67,09	115,70
	6	-15,94	-9,05	-2,48	13,46	-51,55	51,96	103,51
	7	-15,71	-8,92	-2,62	13,09	-49,14	44,06	93,20
	8	-15,55	-9,24	-3,29	12,26	-46,17	40,12	86,29
	9	-12,67	-6,24	0,33	12,99	-70,00	48,16	118,16
	10	-13,46	-6,50	0,16	13,63	-56,95	56,73	113,68
	11	-11,57	-4,70	2,35	13,92	-43,50	42,61	86,11
	12	-10,08	-3,59	3,31	13,39	-53,49	38,83	92,32
Skrzypce	**0**	-393,35	-317,21	-261,39	131,96	-831,53	-90,12	741,41
	1	54,77	79,43	101,55	46,77	-29,11	200,60	229,71
	2	-58,70	-48,51	-38,60	20,10	-103,40	67,35	170,74
	3	0,96	11,26	26,33	25,37	-29,59	67,67	97,26
	4	-27,87	-17,43	-9,03	18,84	-62,15	35,80	97,95
	5	-35,64	-23,72	-13,70	21,94	-63,55	38,26	101,81
	6	-25,52	-19,33	-12,11	13,41	-56,72	53,45	110,17
	7	-14,64	-8,32	-1,17	13,47	-42,13	51,24	93,38
	8	-19,79	-12,41	-3,58	16,21	-49,06	45,27	94,33
	9	-15,04	-6,94	2,72	17,76	-39,08	46,74	85,82
	10	-21,37	-13,85	-3,93	17,43	-55,73	46,37	102,09
	11	-6,65	1,42	10,50	17,15	-47,89	53,45	101,34
	12	-11,89	-3,45	6,10	17,99	-51,56	55,66	107,23

Tabela 4.2: Wybrane statystyki dla 13 współczynników capstralnych Mel dla klasyfikowanych instrumentów.

Wykresy pudełkowe są przejrzystą formą wizualizacji wybranych statystyk opisowych. Umożliwiają intuicyjne porównywanie wybranych instrumentów, rozpoznanie wartości odstających, czy zakres zmienności. Zbiór wykresów pudełkowych dla cech MFCC został przedstawiony na Rysunkach 4.4 i 4.5.

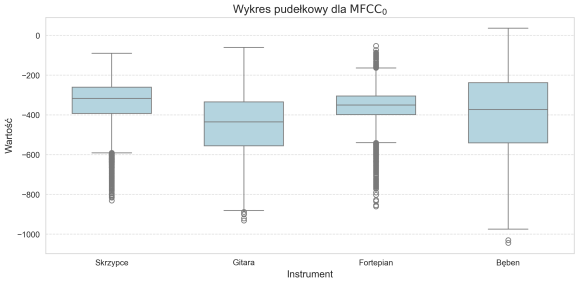

(a) $MFFC_0$

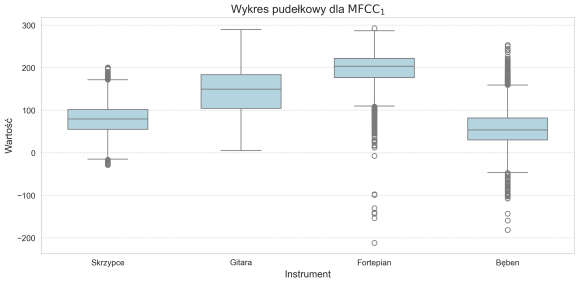

(b) $MFFC_1$

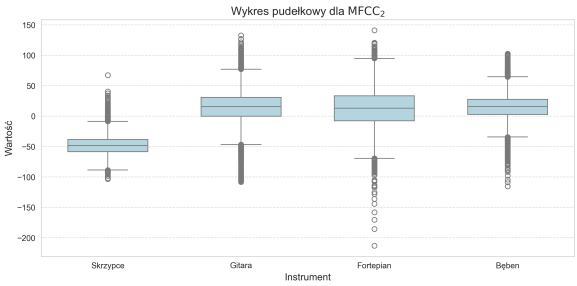

(c) $MFFC_2$

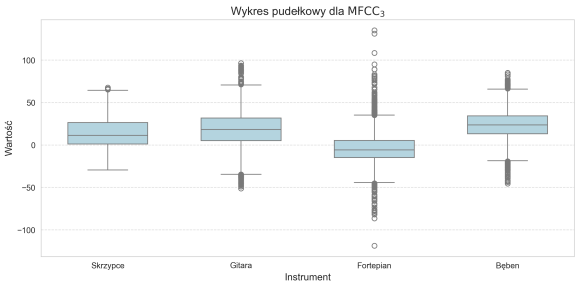

(d) $MFFC_3$

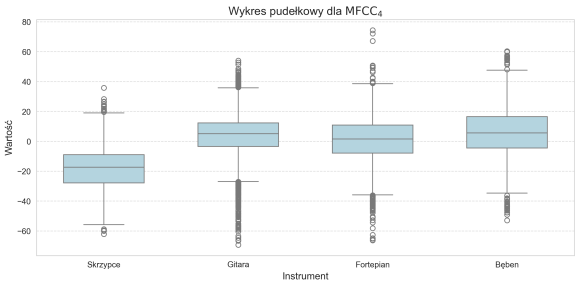

(e) $MFFC_4$

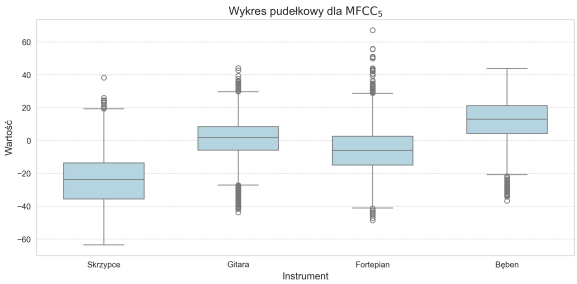

(f) $MFFC_5$

Rysunek 4.4: Zbiór wykresów pudełkowych współczynników cepstralnych Mel ($MFFC_0$ – $MFFC_5$).

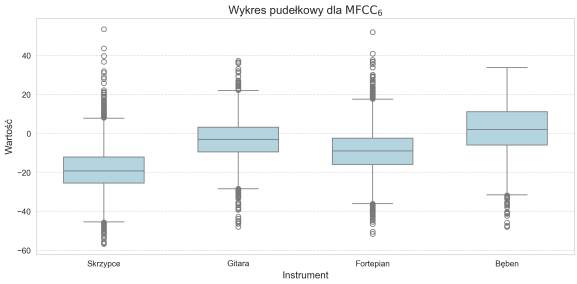

(a) $MFFC_6$

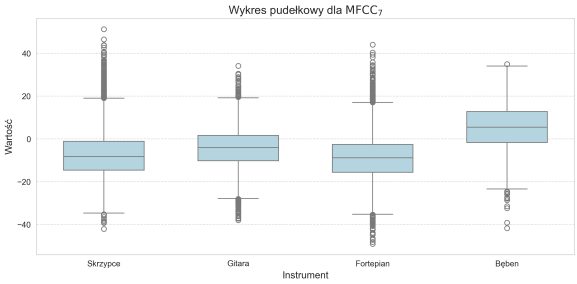

(b) $MFFC_7$

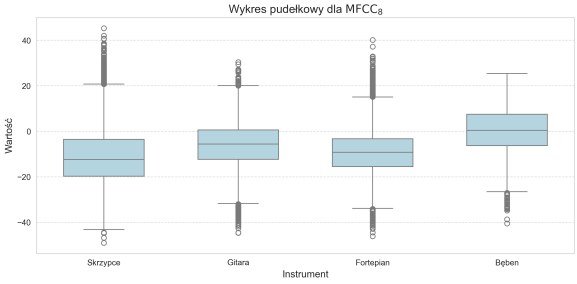

(c) $MFFC_8$

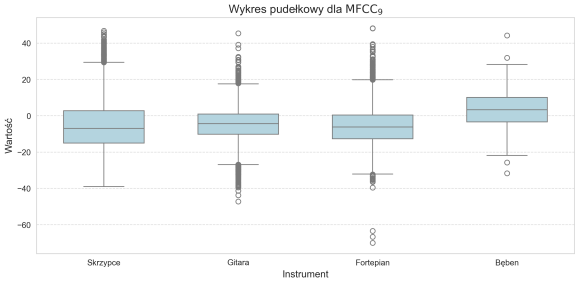

(d) $MFFC_9$

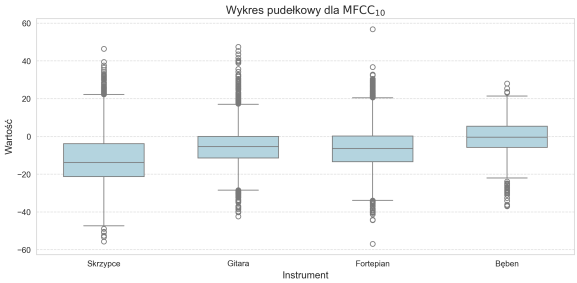

(e) $MFFC_{10}$

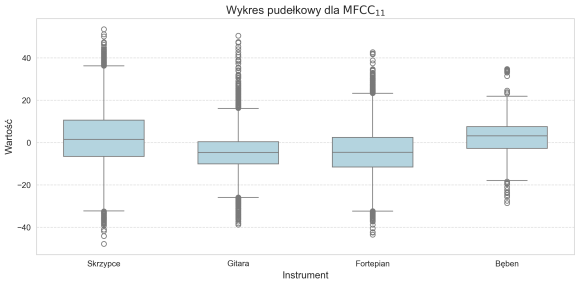

(f) $MFFC_{11}$

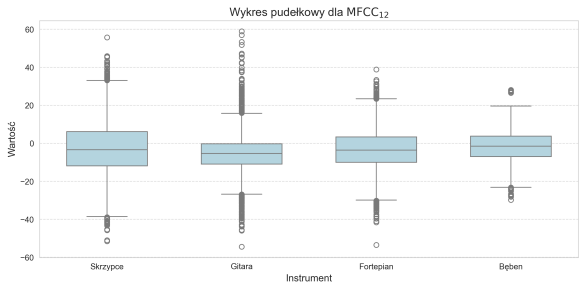

(g) $MFFC_{12}$

Rysunek 4.5: Zbiór wykresów pudełkowych dla współczynników cepstralnych Mel ($MFFC_6$ – $MFFC_{12}$).

Interpretacja wyników

Na podstawie tabeli 4.1 największe odchylenie i wariancję można zaobserwować u wszystkich instrumentów dla jednego konkretnego współczynnika- $MFCC_0$. Dodatkowo, widoczna jest tendencja do zmniejszania się obu tych wartości wraz z wzrostem indeksu $MFCC_i$ z delikatnymi odstępstwami ($MFFC_8$, $MFFC_{12}$) co daje informację, że zróżnicowanie kolejnych wartości wyodrębnionych cech się zmniejsza.

Dominująca jest również kurtoza dodatnia wśród analizowanych wartości $MFCC_i$ instrumentów, wskazuje to na tendencję do większej ilości wartości odstających,a ich rozkłady mają "cięższe" ogony w porównaniu do tych w rozkładzie normalnym. Tylko dla 14 (z czego 8 ulokowanych jest w klasie bębna) współczynników wartość ta jest ujemna, wskazując na to, że dane w tych przypadkach są bardziej skoncentrowane wokół średniej, a ich rozkłady mają "lżejsze" ogony w porównaniu do tych o rozkładzie normalnym.

Współczynnik skośności podzielił instrumenty na dwie główne grupy: bęben i gitara mają dominującą skośność lewostronną, mówiącą o większości obserwacji w próbie, będącej powyżej średniej, a fortepian i skrzypce - prawostronną, co mówi o wynikach poniżej średniej, które przeważają w badanym zbiorze.

Największy współczynnik zmienności w całym zbiorze można zaobserwować dla bębna i jego współczynnika $MFFC_{10}$. Dane mają skłonność do umiarkowanej zmienności z kilkoma z wartościami odstającymi, sugerującymi dużą zmienność.

Średnia arytmetyczna dla każdego instrumentu jest najniższa w przypadku współczynnika $MFFC_0$. Dla skrzypiec i bębna są to wartości podobne. W przypadku bębna, średnia arytmetyczna dla większości współczynników jest dodatnia, a w przypadku skrzypiec ujemna. W całym zbiorze można zaobserowować jednak tendencję do ujemnych wartości średniej.

Analizując tabelę 4.2 i wykresy pudełkowe na Rysunkach 4.5 i 4.4 można wysunąć wniosek, że wstępnie $MFFC_0$, $MFFC_1$ i $MFFC_2$ mogą mieć największy wpływ na klasyfikację instrumentów, z powodu ich większego zróżnicowania w wartościach. Analogicznie można zauważyć, że przy $MFFC_9$ - $MFFC_{12}$, nie ma tak dużego zróżnicowania, co może sugerować, że te współczynniki mogą mieć mniejszy wpływ na wybór klasy przez modele.

Rozdział 5

Analizy

W tym rozdziale przedstawione zostały wyniki najlepszych analizowanych algorytmów nadzorowanego uczenia maszynowego, przeprowadzone z wykorzystaniem wybranych miar oceny jakości modeli tj. dokładności, czułości, precyzji, średniej harmonicznej czułości i precyzji (miara F1) oraz dodatkowej miary: czasu treningu. Zbiór danych jest zbiorem zbalansowanym, a koszta fałszywych alarmów, czy odchyleń są dokładnie takie same, więc uznano, że kryterium dokładności będzie wyznacznikiem uznającym dany model za najlepszy. Z każdego algorytmu wybrano po jednym modelu, który charakteryzuje się najwyższą dokładnością w obrębie swojego algorytmu i na końcu wybrano jeden najlepszy na tle wszystkich algorytmów.

Wszystkie zaprezentowane wyniki zostały osiągnięte dzięki bibliotece języka programowania Python: scikit - learn.

Podstawowe metryki oraz czas treningu zostały zaokrąglone do czterech miejsc po przecinku, raporty klasyfikacji instrumentów - do dwóch, czas treningu został wyrażony w sekundach.

5.1 Losowy model bazowy

Analiza rozpoczęła się oceną wyników losowego modelu bazowego. Model został skonstruowany przy minimalnym dostosowaniu parametrów, bazując na prostych założeniach dotyczących danych - nie ma fazy treningu, a etykiety były przydzielane losowo z prawdopodobieństwem $\frac{1}{4}$.

Tabele i macierz pomyłek

Metryka	**Wartość**
Dokładność	0.2502
Precyzja	0.2503
Czułość	0.2502
Miara F1	0.2502
Czas treningu	0.0010

Tabela 5.1: Podstawowe metryki modelu bazowego.

Klasa	Precyzja	Czułość	Miara F1
Bęben	0.24	0.24	0.24
Gitara	0.25	0.25	0.25
Fortepian	0.24	0.24	0.24
Skrzypce	0.25	0.25	0.25

Tabela 5.2: Raport klasyfikacji instrumentów dla modelu bazowego.

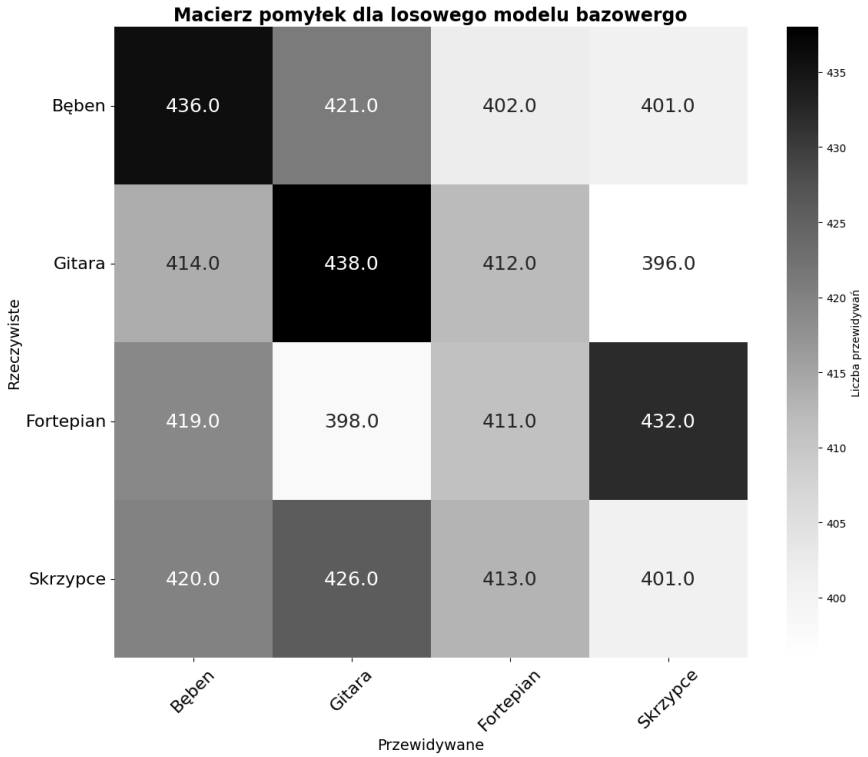

Rysunek 5.1: Macierz pomyłek losowego modelu bazowego.

Wnioski z analizy losowego modelu bazowego

W Tabelach 5.1 i 5.2 zaprezentowano wyniki metryk i raport klasyfikacji dla losowego modelu bazowego. Jak zakładano, model osiągnął w każdym kryterium wyniki po około 25%. Ten model ma niewielkie zdolości do skutecznej klasyfikacji. Można to zauważyć na Rysunku 5.1 przedstawiającego macierz pomyłek dla tego modelu. Z macierzy wynika, że model często mylił klasy, pomyłki są w miarę równomierne, aczkolwiek można zauważyć, że największy problem miał z dźwiękami foretpianu i skrzypiec.

Dzięki tym wynikom, widać potrzebę stosowania zaawansowanych algorytmów uczenia maszynowego, które mogą skuteczniej uchwycić charakterystykę danych i poprawić ogólną jakość klasyfikacji.

5.2 Regresja logistyczna

W celu zbadania możliwości modelu regresji logistycznej wykorzystano dostrajanie modelu przy pomocy hiperparametrów. Przetestowano różne rodzaje regularyzacji (L1, L2, elasticnet), metody optymalizacji (lbfgs, saga, liblinear), wartości regularyzacji (0.01, 0.1, 1.0, 10), maksymalną liczbę iteracji (100, 1000, 10000, 20000) oraz proporcje regularyzacji L1 w elasticnet (0.01, 0.05, 0.1, 0.5). To pozwoliło na znalezienie najlepiej dopasowanej konfiguracji do klasyfikowanego zbioru danych.

Najlepsze modele dla wybranych metryk

Metryka	Regularyzacja	C	Metody optymalizacji	Max. liczba iteracji	Dokładność	Precyzja	Czułość	F1 Score	Czas treningu
Dokładność	L2	0.1	lbfgs	10000	0.8363	0.8341	0.8363	0.8348	18.9385
Precyzja	L2	0.1	lbfgs	10000	0.8363	0.8341	0.8363	0.8348	18.9385
Czułość	L2	0.1	lbfgs	10000	0.8363	0.8341	0.8363	0.8348	18.9385
F1 Score	L2	0.1	lbfgs	10000	0.8363	0.8341	0.8363	0.8348	18.9385
Czas treningu	L2	0.1	lbfgs	100	0.8301	0.8278	0.8301	0.8286	0.3846

Tabela 5.3: Najlepsze modele regresji logistycznej dla każdej metryki.

W Tabeli 5.3 zostały zaprezentowane najlepsze modele dla każdej metryki. Jak można zauważyć model z następujacymi hiperparametrami został wybrany najlepszym w czterech rozważanych metrykach:

- Regularyzacja: L2,
- C: 0.1,
- Metoda optymalizacji: lbfgs,
- Maksymalna liczba iteracji: 10000.

W kryterium czasu treningu został wybrany model z parametrami:

- Regularyzacja: L2,
- C: 0.1,
- Metoda optymalizacji: lbfgs,
- Maksymalna liczba iteracji: 100.

Tabele i macierz pomyłek dla najlepszego modelu

Metryka	Wartość
Dokładność	0.8363
Precyzja	0.8341
Czułość	0.8363
F1 Score	0.8348
Czas treningu	18.9385

Tabela 5.4: Podstawowe metryki najlepszego modelu regresji logistycznej.

Klasa	Precyzja	Czułość	F1 score
Bęben	0.85	0.88	0.86
Gitara	0.73	0.68	0.70
Fortepian	0.81	0.83	0.82
Skrzypce	0.95	0.96	0.95

Tabela 5.5: Raport klasyfikacji instrumentów najlepszego modelu regresji logistycznej.

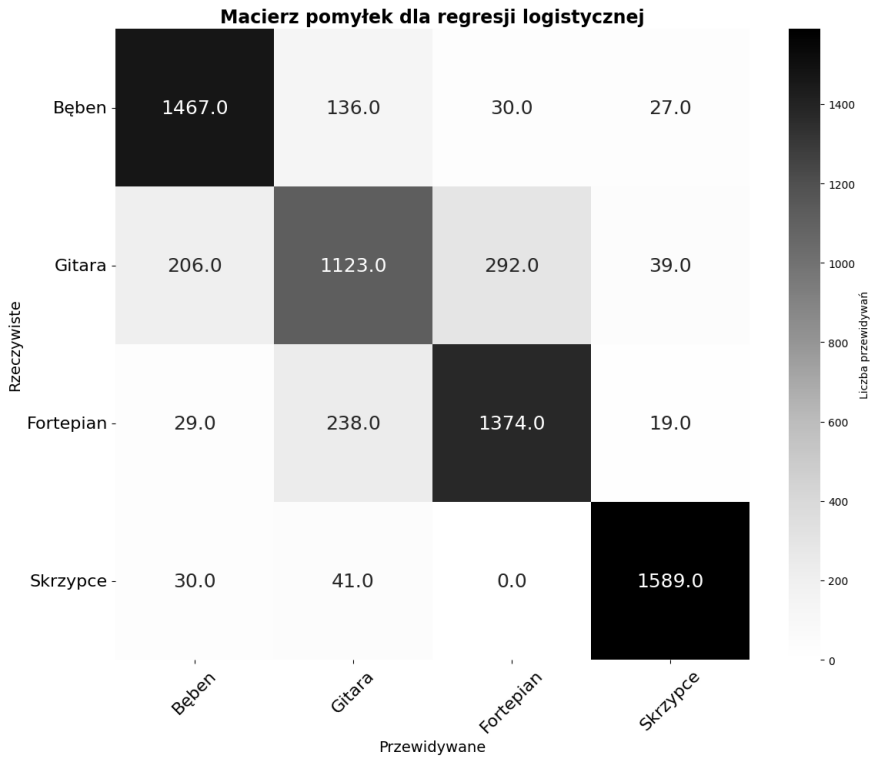

Rysunek 5.2: Macierz pomyłek najlepszego modelu regresji logistcznej.

Wnioski z analizy modelu regresji logistcznej

W Tabelach 5.4 i 5.5 zaprezentowano wyniki metryk i raport klasyfikacji dla najlepszego modelu regresji logistycznej. Model osiągnął dokładność na poziomie około 84%. Wyniki dla innych metryk wahają się również w okolicach 83%. Ten wynik można uznać za obiecujący, biorąc pod uwagę złożoność rozważanych danych. Z macierzy zaprezentowanej na Rysunku 5.2 wynika, że model najgorzej radził sobie w przypadku klasyfikacji klasy gitary - najwięcej razy mylił ją z fortepianem i z bębnem.

Wyniki tej klasyfikacji są dużo lepsze w porównaniu do bazowego modelu losowego. Poprawa jakości o prawie 60 punktów procentowych pokazuje przepaść między tymi modelami. Patrząc na Tabelę 5.3, model, który okazał się najszybszy do trenowania, również ma dość wysoką dokładność wynoszącą około 83%. Tylko 0.0062 dzieli ten model od modelu z najwyższą dokładnością. W przypadku kosztownego treningu, ten model wydawałby się lepszym wyborem w kwestii modeli regresji logistycznej.

5.3 Naiwny klasyfikator Bayesa

W celu zbadania możliwości modeli naiwnych klasyfikatorów Bayesa wykorzystano dostrajanie modelu przy pomocy hiperparametrów. Dla klasyfikatorów *MultinomialNB* i *BernoulliNB* analizowano wpływ wartości parametru wygładzania Laplace'a (α), przyjmując wartości: 0.001, 0.01, 0.1, 1, 10, oraz 100. Dla GaussianNB wybrano domyślny parametr (var smoothing = 1×10^{-9}), który odpowiada za dodanie niewielkiej wartości do wariancji każdego atrybutu. Dzięki temu, uniknięto problemów z przeuczeniem lub zbytnim uogólnieniem modeli. To pozwoliło na znalezienie najlepiej dopasowanej konfiguracji do klasyfikowanego zbioru danych.

Najlepsze modele dla wybranych metryk

Metryka	**Klasyfikator**	**Parametry**	**Dokładność**	**Precyzja**	**Czułość**	**F1 Score**	**Czas treningu (s)**
Dokładność	GaussianNB	1×10^{-9}	0.7642	0.7510	0.7642	0.7469	0.0190
Precyzja	MultinomialNB	1	0.7598	0.7537	0.7598	0.7524	0.0001
Czułość	GaussianNB	1×10^{-9}	0.7642	0.7510	0.7642	0.7469	0.0190
Miara F1	MultinomialNB	1	0.7598	0.7537	0.7598	0.7524	0.0001
Czas treningu	MultinomialNB	1	0.7598	0.7537	0.7598	0.7524	0.0001

Tabela 5.6: Najlepsze modele naiwnego klasyfikatora Bayesa dla każdej metryki.

W Tabeli 5.6 zostały zaprezentowane najlepsze modele dla każdej metryki. Model z klasyfikatorem GaussianNB i domyślną wartością parametru został wybrany jako najlepszy w kryterium dokładności i czułości. Drugim modelem, który osiągnął najlepsze wyniki w przypadku kryterium precyzji, miary F1 i czasu treningu jest model z klasyfikatorem MultinomialNB i parametrem $\alpha = 1$.

Tabele i macierz pomyłek dla najlepszego modelu

Metryka	**Wartość**
Dokładność	0.7642
Precyzja	0.7510
Czułość	0.7642
Miara F1	0.7469
Czas treningu	0.0190

Tabela 5.7: Podstawowe metryki najlepszego modelu naiwnego klasyfikatora Bayesa.

Klasa	Precyzja	Czułość	Miara F1
Bęben	0.73	0.78	0.75
Gitara	0.59	0.53	0.55
Fortepian	0.79	0.82	0.81
Skrzypce	0.94	0.94	0.94

Tabela 5.8: Raport klasyfikacji instrumentów dla najlepszego modelu naiwnego klasyfikatora Bayesa.

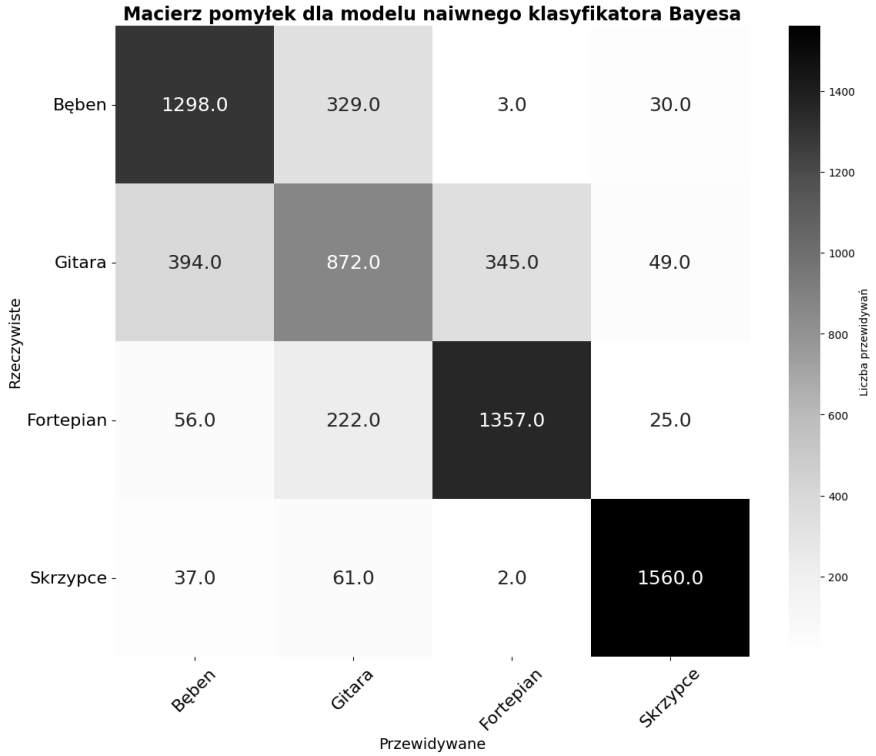

Rysunek 5.3: Macierz pomyłek najlepszego modelu naiwnego klasyfikatora Bayesa.

Wnioski z analizy modelu naiwnego klasyfikatora Bayesa

W Tabelach 5.7 i 5.8 zaprezentowano wyniki metryk i raport klasyfikacji dla najlepszego modelu naiwnych klasyfikatorów Bayesa. Model osiągnął dokładność około 76%. Wyniki dla innych metryk wahają się rónież w okolicach 74% do 76%. Te rezultaty jednak nie są tak zadawalające jak np. w przypadku opisanej już regresji logistycznej, aczkolwiek widać duże usprawnienie w porównaniu do losowego modelu bazowego. Sugeruje to, że ten algorytm nie do końca jest odpowiedni dla rozważanego problemu. Z postaci macierzy pomyłek widniejącej na Rysunku 5.3 można zauważyć, że również i w tym przypadku model nie do końca poradził sobie z rozpoznawaniem klasy gitary.

5.4 Metoda K - najbliższych sąsiadów

W celu zbadania możliwości metody K - najbliższych sąsiadów wykorzystano dostrajanie modelu przy pomocy hiperparametrów. Przetestowano różne liczby sąsiadów (od 1 do 100), dwie metryki (taksówkowa, euklidesowa), wagi sąsiadów (ważeni, jednostkowi). To pozwoliło na znalezienie najlepiej dopasowanej konfiguracji do klasyfikowanego zbioru danych.

Najlepsze modele dla wybranych metryk

Metryka	Liczba sąsiadów	Wagi sąsiadów	Metryka w przestrzeni liniowej	Dokładność	Precyzja	Czułość	Miara F1	Czas treningu
Dokładność	4	ważeni	euklidesowa	0.9517	0.9518	0.9517	0.9517	0.0792
Precyzja	4	ważeni	euklidesowa	0.9517	0.9518	0.9517	0.9517	0.0792
Czułość	4	ważeni	euklidesowa	0.9517	0.9518	0.9517	0.9517	0.0792
Miara F1	4	ważeni	euklidesowa	0.9517	0.9518	0.9517	0.9517	0.0792
Czas treningu	3	jednostkowi	euklidesowa	0.9453	0.9455	0.9453	0.9453	0.0710

Tabela 5.9: Najlepsze modele dla każdej metryki dla metody K - najbliższych sąsiadów.

W Tabeli 5.9 zostały zaprezentowane najlepsze modele dla każdej metryki. Model korzystający z 4 ważonych sąsiadów przy użyciu metryki euklidesowej został uznany najlepszym w każdym kryterium, oprócz czasu treningu, gdzie za najlepszy uznano model z 3 jednostkowymi sąsiadami z użyciem metryki taksówkowej.

Tabele i macierz pomyłek dla najlepszego modelu

Metryka	Wartość
Dokładność	0.9517
Precyzja	0.9518
Czułość	0.9517
Miara F1	0.9517
Czas treningu	0.0792

Tabela 5.10: Podstawowe metryki najlepszego modelu metody K - najbliższych sąsiadów.

Klasa	Precyzja	Czułość	Miara F1
Bęben	0.97	0.98	0.97
Gitara	0.91	0.93	0.92
Fortepian	0.94	0.92	0.93
Skrzypce	0.98	0.98	0.98

Tabela 5.11: Raport klasyfikacji instrumentów dla najlepszego modelu metody K - najbliższych sąsiadów.

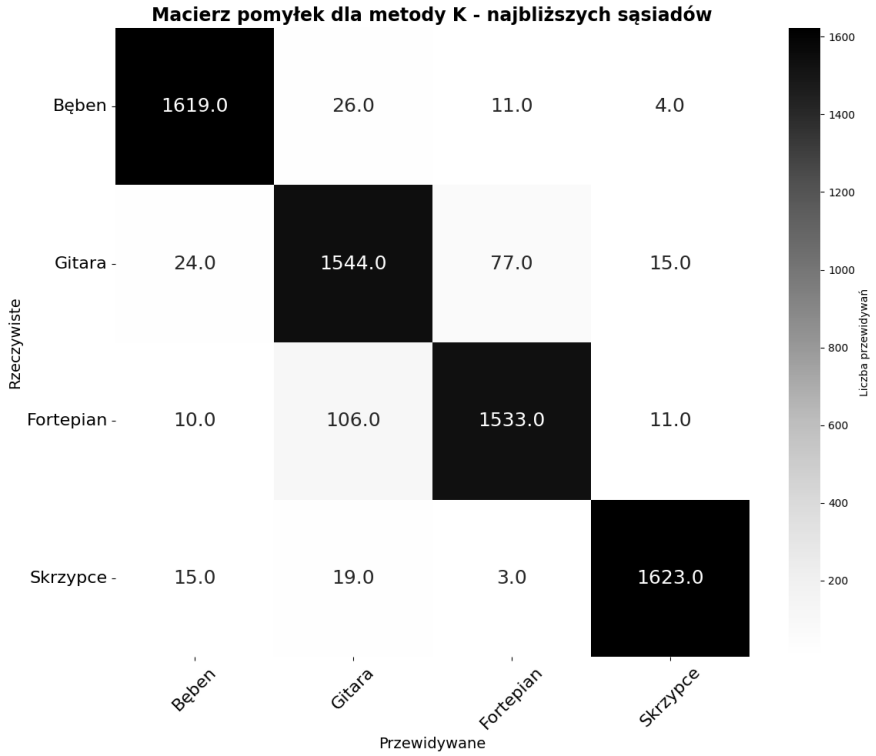

Rysunek 5.4: Macierz pomyłek najlepszego modelu metody K - najbliższych sąsiadów.

Wnioski z analizy modelu metody K - najbliższych sąsiadów

W Tabelach 5.10 i 5.11 zaprezentowano wyniki metryk i raport klasyfikacji dla najlepszego modelu metody K - najbliższych sąsiadów. Model ten osiągnał dokładność około 95%, z innymi metrykami na podobnym poziomie procentowym. Wskazuje to na to, że ten algorytm może być uważany za odpowiedni przy klasyfikacji instrumentów. Z macierzy zaprezentowanej na Rysunku 5.4 widać, że w ogólności model dobrze poradził sobie z klasyfikacją, jedyne małe odstępstwa są widoczne przy doborze etykiet dla klasy fortepianu i gitary.

5.5 Drzewo decyzyjne i jego wzmocnienia

W celu zbadania możliwości drzewa decyzyjnego wykorzystano dostrajanie modelu przy pomocy hiperparametrów. Przetestowano różne maksymalne głębokości drzewa (od 1 do 50), kryterium zysku informacji (Gini, Entropia) oraz kryterium podziału (losowe, najlepsze). To pozwoliło na znalezienie najlepiej dopasowanej konfiguracji do klasyfikowanego zbioru danych.

Najlepsze modele dla wybranych metryk

Metryka	Kryterium zysku informacji	Max. głębokość	Kryterium podziału	Dokładność	Precyzja	Czułość	Miara F1	Czas treningu
Dokładność	Entropia	22	najlepsze	0.9119	0.9118	0.9119	0.9118	0.8952
Precyzja	Entropia	22	najlepsze	0.9119	0.9118	0.9119	0.9118	0.8952
Czułość	Entropia	22	najlepsze	0.9119	0.9118	0.9119	0.9118	0.8952
Miara F1	Entropia	22	najlepsze	0.9119	0.9118	0.9119	0.9118	0.8952
Czas treningu	Entropia	1	losowe	0.4660	0.2547	0.4660	0.3212	0.0050

Tabela 5.12: Najlepsze modele dla każdej metryki dla drzewa decyzyjnego.

W Tabeli 5.12 zostały zaprezentowane najlepsze modele dla każdej metryki. Model korzystający z entropii przy maksymalnej głębokości 22 i najlepszym kryterium podziału okazał się najlepszym w wszystkich kryteriach oprócz czas treningu, gdzie najlepszym okazał się model korzystający z tego samego kryterium zysku informacji, ale z maksymalną głębokością 1 i losowym kryterium podziału.

Tabele i macierz pomyłek dla najlepszego modelu

Metryka	Wartość
Dokładność	0.9119
Precyzja	0.9118
Czułość	0.9119
Miara F1	0.9118
Czas treningu	0.8952

Tabela 5.13: Podstawowe metryki najlepszego modelu drzewa decyzyjnego.

Klasa	Precyzja	Czułość	Miara F1
Bęben	0.94	0.95	0.95
Gitara	0.85	0.85	0.85
Fortepian	0.89	0.88	0.88
Skrzypce	0.97	0.97	0.97

Tabela 5.14: Raport klasyfikacji instrumentów dla najlepszego modelu drzewa decyzyjnego.

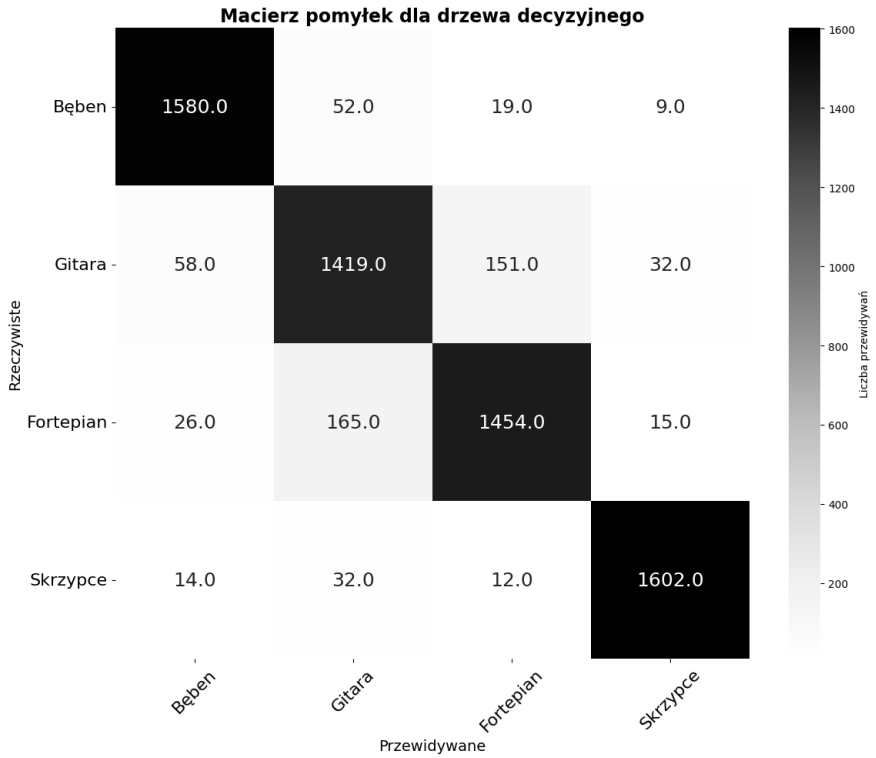

Rysunek 5.5: Macierz pomyłek najlepszego modelu drzewa decyzyjnego.

Wnioski z analizy modelu drzewa decyzyjnego

W Tabelach 5.13 i 5.14 zaprezentowano wyniki metryk i raport klasyfikacji dla najlepszego modelu drzewa decyzyjnego. Model ten osiągnał dokładność około 91%. Jest to wynik zadowalający, przewyższający mocno model podstawowy. Z macierzy widocznej na Rysunku 5.5 widać, że model nie miał większych problemów z klasyfikacją skrzypiec, czy bębna, ale widać, że były niedociągnięcia w przypadku klasy gitary i fortepianu.

5.5.1 Wzmocnienia

W celu zbadania możliwości trzech wzmocnień drzewa decyzyjnego (Bagging, Boosting i Las losowy) wykorzystano dostrajanie modeli przy pomocy hiperparametrów. Dla obu wzmocnień - Baggingu i Lasu losowego - przetestowano różne liczby drzew decyzyjnych (od 1 do 100), podzbiory ilości danych (0.5, 0.7, 1.0). Dla samego lasu losowego dodatkowo przetestowano podzbiory ilości cech (sqrt, log2). Dla Boostingu sprawdzono liczby drzew decyzyjnych (od 1 do 100) i współczynnik uczenia (0.1, 0.5). To pozwoliło na znalezienie najlepiej dopasowanej konfiguracji do klasyfikowanego zbioru danych.

Najlepsze modele dla wybranych metryk

Metryka	Liczba estymatorów	Podzbiór przykładów	Podzbiór cech	Dokładność	Precyzja	Czułość	Miara F1	Czas treningu
Dokładność	55	1	sqrt	0.9522	0.9522	0.9522	0.9523	6.5843
Precyzja	94	1	sqrt	0.9522	0.9522	0.9522	0.9523	11.2531
Czułość	55	1	sqrt	0.9522	0.9522	0.9522	0.9523	6.5843
Miara F1	94	1	sqrt	0.9522	0.9522	0.9522	0.9523	11.2531
Czas treningu	1	0.5	log2	0.8550	0.8550	0.8550	0.8550	0.0731

Tabela 5.15: Najlepsze modele dla każdej metryki dla lasu losowego.

Metryka	Liczba estymatorów	Podzbiór przykładów	Dokładność	Precyzja	Czułość	Miara F1	Czas treningu
Dokładność	52	1	0.9430	0.9430	0.9430	0.9430	22.1029
Precyzja	52	1	0.9430	0.9430	0.9430	0.9430	22.1029
Czułość	52	1	0.9430	0.9430	0.9430	0.9430	22.1029
Miara F1	52	1	0.9430	0.9430	0.9430	0.9430	22.1029
Czas treningu	1	0.5	0.8138	0.8131	0.8138	0.8128	0.1050

Tabela 5.16: Najlepsze modele dla każdej metryki dla Baggingu.

Metryka	Liczba estymatorów	Współczynnik uczenia	Dokładność	Precyzja	Czułość	Miara F1	Czas treningu
Dokładność	98	0.5	0.9298	0.9297	0.9298	0.9297	51.9501
Precyzja	98	0.5	0.9298	0.9297	0.9298	0.9297	51.9501
Czułość	98	0.5	0.9298	0.9297	0.9298	0.9297	51.9501
Miara F1	98	0.5	0.9298	0.9297	0.9298	0.9297	51.9501
Czas treningu	1	0.5	0.8295	0.8300	0.8295	0.8315	0.5553

Tabela 5.17: Najlepsze modele dla każdej metryki dla Boostingu.

W Tabelach 5.15, 5.16 i 5.17 zostały zaprezentowane najlepsze modele dla każdej metryki dla każdego ze wzmocnień. Wybrano jeden model, który charakteryzuje się najwyższą dokładnością ze wszystkich wzmocnień - model drzewa decyzyjnego przy użyciu wzmocnienia za pomocą lasu losowego składającego się z 55 estymatorów, podzbiorem cech z pierwiastka z oryginalnej ich liczby oraz przy użyciu całego zbioru danych. Nie jest zaskakującym, że w każdym z przypadków najkrótszym czasem treningu charakteryzują się modele z jednym estymatorem. Najlepszy model Baggingu, nie dość, że ma większą dokładność to jego czas treningu jest praktycznie o połowę krótszy od najlepszego modelu Boostingu.

Tabele i macierz pomyłek dla najlepszego modelu.

Metryka	Wartość
Dokładność	0.9522
Precyzja	0.9522
Czułość	0.9522
Miara F1	0.9523
Czas treningu	6.5843

Tabela 5.18: Podstawowe metryki najlepszego modelu lasu losowego.

Klasa	Precyzja	Czułość	Miara F1
Bęben	0.97	0.98	0.98
Gitara	0.81	0.92	0.92
Fortepian	0.94	0.93	0.94
Skrzypce	0.98	0.98	0.98

Tabela 5.19: Raport klasyfikacji instrumentów dla najlepszego modelu lasu losowego.

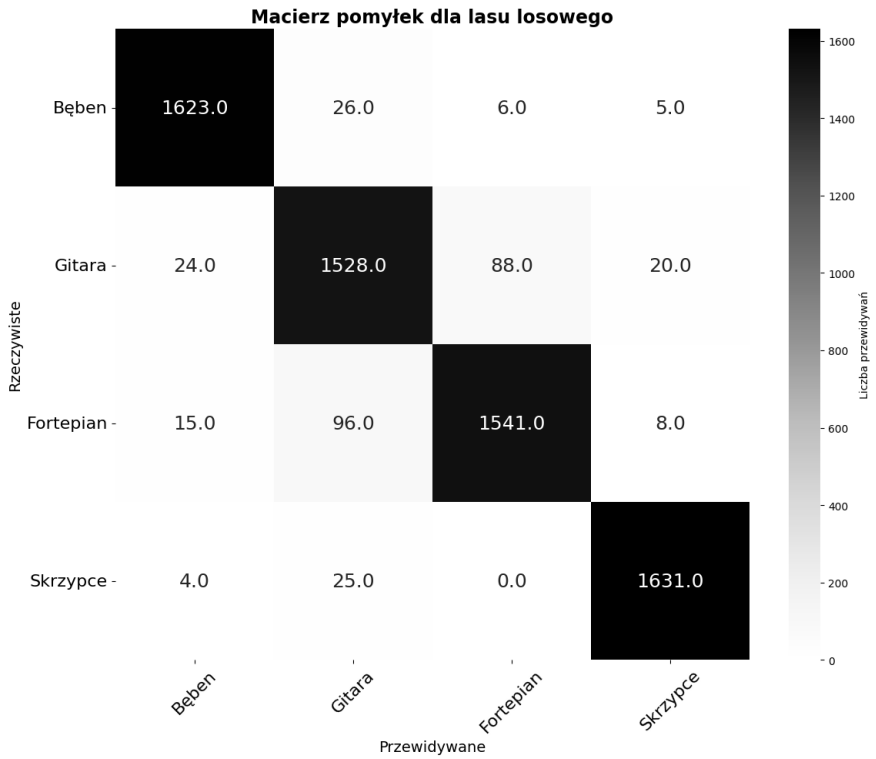

Rysunek 5.6: Macierz pomyłek najlepszego modelu lasu losowego.

Wnioski z analizy modelu drzewa decyzyjnego ze wzmocnieniami

W Tabelach 5.18 i 5.19 zaprezentowano wyniki metryk i raport klasyfikacji dla najlepszego modelu drzewa decyzyjnego przy użyciu wzmocnienia lasu losowego. Model ten osiągnął dokładność na poziomie około 95%, co potwierdza, że połączenie wielu słabych modeli może prowadzić do zwiększenia dokładności modelu. W każdym ze wzmocnień można zauważyć poprawę jakości modelu drzewa decyzyjnego. Wynik na poziomie 95% jest obiecujący w kontekście klasyfikacji instrumentów. Z macierzy zaprezentowanej na Rysunku 5.6 widać, że model dobrze poradził sobie z doborem klas do przykładów, widać nawet podobieństwo z drzewem decyzyjnym w umiejscownieniu największej liczby przeoczeń i fałszywych alarmów.

5.6 Maszyna wektorów nośnych

W celu zbadania możliwości modeli maszyny wektorów nośnych wykorzystano dostrajanie modelu przy pomocy hiperparemetrów. Przetestowano dwa różne rodzaje funkcji jądra (liniowe, RBF) oraz wartości C (0.001, 0.01, 0.1, 1.0, 10). To pozwoliło na znalezienie najlepiej dopasowanej konfiguracji do klasyfikowanego zbioru danych.

Najlepsze modele dla wybranych metryk

Metryka	**Funkcja jądra**	**C**	**Dokładność**	**Precyzja**	**Czułość**	**Miara F1**	**Czas treningu**
Dokładność	RBF	10	0.9012	0.9000	0.9012	0.9004	7.6117
Precyzja	RBF	10	0.9012	0.9000	0.9012	0.9004	7.6117
Czułość	RBF	10	0.9012	0.9000	0.9012	0.9004	7.6117
Miara F1	RBF	10	0.9012	0.9000	0.9012	0.9004	7.6117
Czas treningu	RBF	10	0.9012	0.9000	0.9012	0.9004	7.6117

Tabela 5.20: Najlepsze modele dla każdej metryki dla SVM.

W Tabeli 5.23 zostały zaprezentowane najlepsze modele dla każdej metryki. Jak można zauważyć jeden model został wybrany najlepszym w każdej z wybranych metryk, co jest jedynym taki przypadkiem spotkanym w pracy. Ten model wykorzystuje jądro RBF z wartością $C = 10$.

Tabele i macierz pomyłek dla najlepszego modelu

Metryka	**Wartość**
Dokładność	0.9012
Precyzja	0.9000
Czułość	0.9012
Miara F1	0.9004
Czas treningu	7.6117

Tabela 5.21: Podstawowe metryki najlepszego modelu SVM.

Klasa	Precyzja	Czułość	Miara F1
Bęben	0.92	0.95	0.93
Gitara	0.85	0.80	0.82
Fortepian	0.87	0.87	0.87
Skrzypce	0.96	0.98	0.97

Tabela 5.22: Raport klasyfikacji instrumentów dla najlepszego modelu SVM.

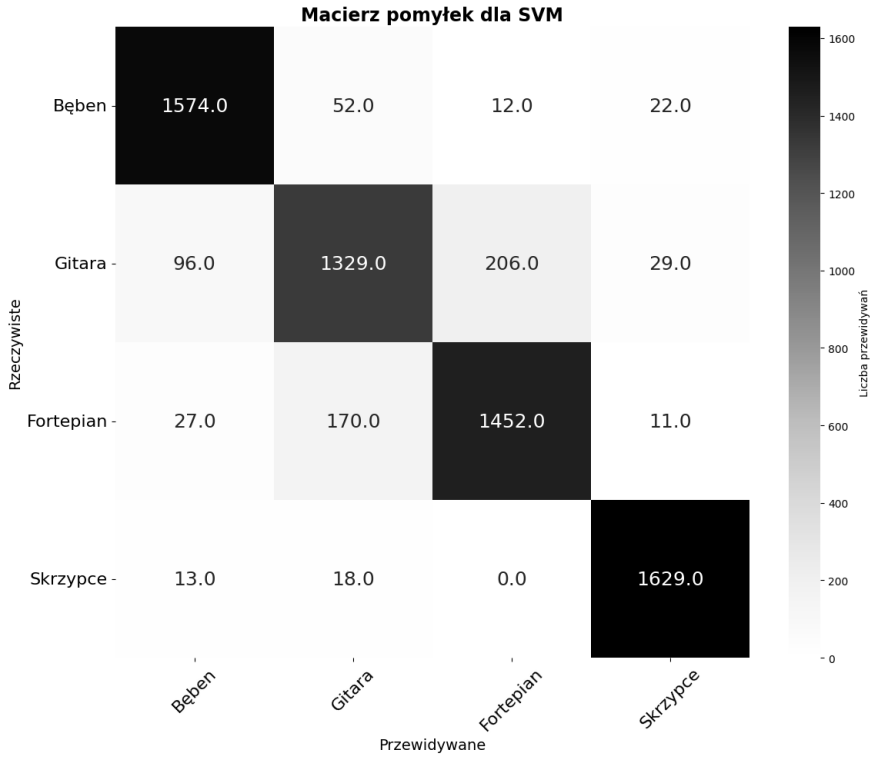

Rysunek 5.7: Macierz pomyłek najlepszego modelu SVM.

Wnioski z analizy modelu maszyny wektorów nośnych

W Tabelach 5.21 i 5.22 zaprezentowano wyniki metryk i raport klasyfikacji dla najlepszego modelu SVM. Model ten osiągnął dokładność na poziomie około 90%, z innymi metrykami na podobnym poziomie. Jest to model z zadowalającą dokładnością, choć w pracy pojawiły się modele lepszej jakości w kontekście rozważanego problemu klasyfikacji. Z macierzy zaprezentowanej na Rysunku 5.7 widać, że model dobrze poradził sobie z doborem klas do przykładów, aczkolwiek największy problem miał z doborem etykiety dla klasy gitary.

5.7 Sieci neuronowe

W celu zbadania możliwości modelu sieci neuronowej wykorzystano dostrajanie modelu przy pomocy hiperparametrów. Przetestowano różne rozmiary warstw ukrytych, funkcji aktywacji (relu, tanh), algorytmów optymalizacji (adam, sgd) oraz współczynników uczenia (constant, adaptive). To pozwoliło na znalezienie najlepiej dopasowanej konfiguracji do klasyfikowanego zbioru danych.

Najlepsze modele dla wybranych metryk

Metryka	Ukryte warstwy	Funkcja aktywacji	Algorytm optymalizacji	Współczynnik uczenia	Dokładność	Precyzja	Czułość	Miara F1	Czas treningu
Dokładność	(150, 150)	relu	adam	constant	0.9623	0.9625	0.9623	0.9624	105.5970
Precyzja	(150, 150)	relu	adam	constant	0.9623	0.9625	0.9623	0.9624	105.5970
Czułość	(150, 150)	relu	adam	constant	0.9623	0.9625	0.9623	0.9624	105.5970
Miara F1	(150, 150)	relu	adam	constant	0.9623	0.9625	0.9623	0.9624	105.5970
Czas treningu	(100, 50)	tahn	sgd	constant	0.8510	0.8561	0.8510	0.8514	4.0721

Tabela 5.23: Najlepsze modele sieci neuronowej dla każdej metryki.

W Tabeli 5.23 zostały zaprezentowane najlepsze modele dla każdej metryki. Jak można zauważyć model z hiperparametrami - (150,150) ukrytych warstw (tj. dwie ukryte warstwy, każda po 150 neuronów), relu jako funkcja aktywacji, adam jako algorytm optymalizacji oraz współczynnik uczenia constant, został wybrany najlepszym w czterech rozważanych metrykach. Jedynie w kryterium czasu treningu został wybrany model z parametrami kolejno: (100, 50), tanh, sgd, constant.

Tabele i macierz pomyłek dla najlepszego modelu

Metryka	Wartość
Dokładność	0.9623
Precyzja	0.9625
Czułość	0.9623
Miara F1	0.9624
Czas treningu	105.5970

Tabela 5.24: Podstawowe metryki najlepszego modelu sieci neuronowej.

Klasa	Precyzja	Czułość	Miara F1
Bęben	0.96	0.98	0.97
Gitara	0.94	0.92	0.93
Fortepian	0.94	0.93	0.94
Skrzypce	0.99	0.99	0.99

Tabela 5.25: Raport klasyfikacji instrumentów dla najlepszego modelu sieci neuronowej.

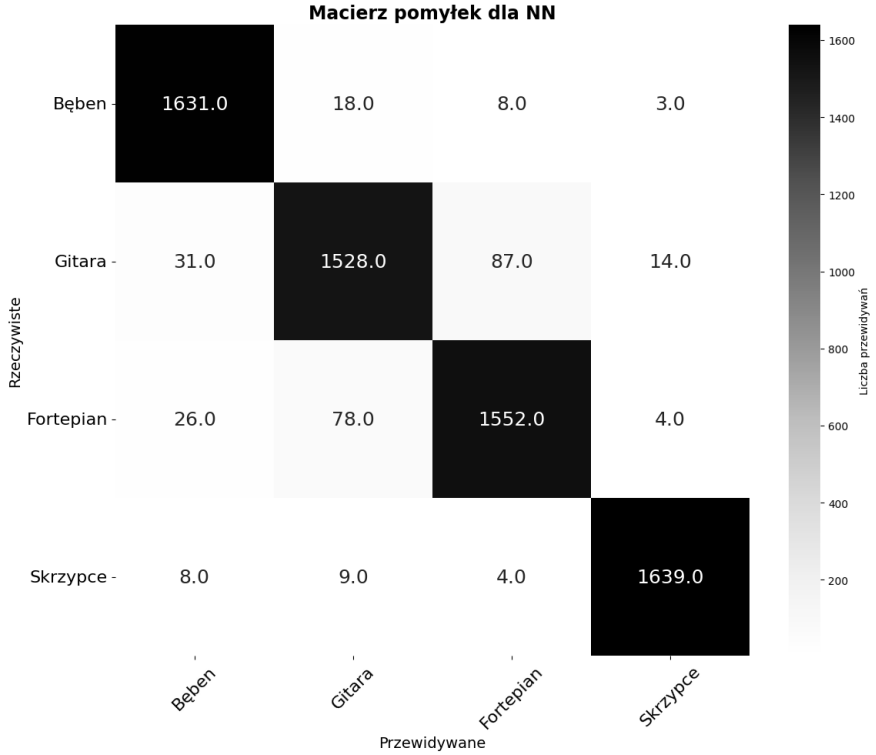

Rysunek 5.8: Macierz pomyłek najlepszego modelu sieci neuronowej.

Wnioski z analizy modelu sieci neuronowych

W Tabelach 5.24 i 5.25 zaprezentowano wyniki metryk i raport klasyfikacji dla najlepszego modelu sieci neuronowej. Model ten osiągnął dokładność na poziomie około 96%, co wskazuje na bardzo wysoką skuteczność modelu w rozpoznawaniu kategorii instrumentów wybranego problemu. Model wydaje się być dobrze dostrojony i skutecznie uczy się wzorców różnicujących instrumenty. Na Rysunku 5.8 widać, że model bardzo dobrze poradził sobie z doborem klas do przykładów z delikatnymi odstępstwami w klasie gitary i fortepianu.

5.8 Eksperymenty

Ta sekcja przeznaczona jest dodatkowym eksperymentom sprawdzającym wpływ innych, dodatkowych czynników na jakość badanych modeli. Eksperymenty pozwoliły na sprawdzenie, w jaki sposób zmiana przygotowania zbioru danych wpływa na rezultaty algorytmów.

W pracy zastosowano dwa kluczowe aspekty w przygotowywaniu danych:

- Zmiana długości plików audio - oprócz standardowego podziału na 1 sekundowe pliki audio, podzielono zbiór danych również na pliki 3 sekundowe i 5 sekundowe, ekstrahując dokładnie tyle samo cech do w pierwotnej analizie - 13.
- Wyodrębnienie większej liczby cech MFCC - oprócz analizowanych przykładów z 13 wyodrębnionymi cechami przeanalizowano te same przykłady tylko z 30 i 50 cechami.

W analizie wpływu różnych możliwości przygotowania danych skorzystano z dokładnie takich samych parametrów każdego z badanych algorytmów, jak w przypadku standardowej analizy wspomnianej w rozdziałach 5.1-5.7, aby móc jak najdokładniej porównać wyniki.

Regresja logistyczna

Liczba cech	Regularyzacja	C	Metody optymalizacji	Max. liczba iteracji	Dokładność
30 cech	L1	10	saga	1000	0.8637
50 cech	L2	0.01	lbfgs	20000	0.8742

Tabela 5.26: Wyniki eksperymentów najlepszych modeli regresji logistycznej przy wyodrębnieniu 30 i 50 cech MFCC.

Długość plików	Regularyzacja	C	Metody optymalizacji	Max. liczba iteracji	Dokładność
3 sekundy	L2	0.01	lbfgs	1000	0.8465
5 sekund	L1	1	saga	1000	0.8772

Tabela 5.27: Wyniki eksperymentów najlepszych modeli regresji logistycznej przy użyciu 3 i 5 sekundowych plików audio.

W Tabelach 5.26 i 5.27 zeprezentowano wyniki z zakresu dokładności najlepszych modeli regresji logistycznej rozważanych w kategorii eksperymentów. Można zauważyć, że hiperparametry najlepszych modeli zmieniają się wraz zmianą sposobu przygotowywania danych. Wszystkie te modele przewyższają jakością wybrany najlepszym model z wcześniejszej analizy, który osiągnął dokładność 0.8363 (podrozdział 5.2). W przypadku tego algorytmu optymalnym jest wybranie wariacji z 5 sekundowymi plikami audio.

Naiwny klasyfikator Bayesa

Liczba cech	Klasyfikator	Parametry	Dokładność
30	GaussianNB	1×10^{-9}	0.7641
50	GaussianNB	1×10^{-9}	0.7776

Tabela 5.28: Wyniki eksperymentów najlepszych modeli naiwnych klasyfikatorów Bayesa przy wyodrębnieniu 30 i 50 cech MFCC.

Długość plików	Klasyfikator	Parametry	Dokładność
3 sekundy	GaussianNB	1×10^{-9}	0.7435
5 sekund	MultinomialNB	100	0.7469

Tabela 5.29: Wyniki eksperymentów najlepszych modeli naiwnych klasyfikatorów Bayesa przy użyciu 3 i 5 sekundowych plików audio.

Tabele 5.29 i 5.29 prezentujące wyniki eksperymentów pokazują, że tylko jeden model (50 cech) przewyższa dokładnością model z wcześniejszej analizy o około 1 punkt procentowy. Mimo tej poprawy wyniki nadal odstają od innych omawianych modeli, co tylko wzmacnia sugestię o tym, że ten algorytm nie jest dobrym wyborem do tego typu problemu klasyfikacji instrumentów.

Metoda K - najbliższych sąsiadów

Liczba cech	Liczba sąsiadów	Wagi sąsiadów	Metryka w przestrzeni liniowej	Dokładność
30	1	jednostkowi	euklidesowa	0.9751
50	1	jednostkowi	euklidesowa	0.9820

Tabela 5.30: Wyniki eksperymentów najlepszych modeli metody K - najbliższych sąsiadów przy wyodrębnieniu 30 i 50 cech MFCC.

Długość plików	Liczba sąsiadów	Wagi sąsiadów	Metryka w przestrzeni liniowej	Dokładność
3 sekundy	1	jednostkowi	euklidesowa	0.9607
5 sekund	1	jednostkowi	euklidesowa	0.9640

Tabela 5.31: Wyniki eksperymentów najlepszych modeli metody K - najbliższych sąsiadów przy użyciu 3 i 5 sekundowych plików audio.

W Tabelach 5.30 i 5.31 widnieją wyniki eksperymentów w zakresie metody K - najbliższych sąsiadów. Wyniki każdego modelu w kryterium dokładności są lepsze od pierwotnie analizowanego, którego dokładność wynosi 0.9517 (podrozdział 5.4). Każdy z poszczególnych najlepszych modeli charakteryzuje się tymi samymi hiperparametrami. Model opisujący 50 cech MFCC osiągnął wynik powyżej 98% co sprawia, że jest wysoce skuteczny w klasyfikacji instrumentów.

Drzewo decyzyjne

Liczba cech	Kryterium zysku informacji	Max. głębokość	Kryterium podziału	Dokładność
30	Entropia	18	najlepsze	0.9138
50	Entropia	21	najlepsze	0.9176

Tabela 5.32: Wyniki eksperymentów najlepszych modeli drzewa decyzyjnego przy wyodrębnieniu 30 i 50 cech MFCC.

Długość plików	Kryterium zysku informacji	Max. głębokość	Kryterium podziału	Dokładność
3 sekundy	Entropia	15	najlepsze	0.9194
5 sekund	Wskaźnik Giniego	12	najlepsze	0.9297

Tabela 5.33: Wyniki eksperymentów najlepszych modeli drzewa decyzyjnego przy użyciu 3 i 5 sekundowych plików audio.

W Tabelach 5.32 i 5.33 widnieją wyniki eksperymentów w zakresie drzewa decyzyjnego. Wyniki każdego modelu w kryterium dokładności są lepsze od pierwotnie analizowanego, którego dokładność wynosi 0.9119 (podrozdział 5.5). Najlepszym okazał się model, używający wskaźnika Giniego jako kryterium zysku informacji.

Wzmocnienia

Liczba cech	Wzmocnienie	Liczba estymatorów	Podzbiór przykładów	Podzbiór cech	Współczynnik uczenia	Dokładność
30	Las losowy	60	1	log2	-	0.9603
50		80	1	log2	-	0.9672
30	Bagging	69	1	-	-	0.9521
50		75	0.7	-	-	0.9218
30	Boosting	94	-	-	0.5	0.9523
50		99	-	-	0.5	0.9568

Tabela 5.34: Wyniki eksperymentów najlepszych modeli drzewa decyzyjnego ze wzmocnieniami przy przy wyodrębnieniu 30 i 50 cech MFCC.

Długość plików	Wzmocnienie	Liczba estymatorów	Podzbiór przykładów	Podzbiór cech	Współczynnik uczenia	Dokładność
3 sekundy	Las losowy	49	0.7	sqrt	-	0.9565
5 sekund		50	1	sqrt	-	0.9586
3 sekundy	Bagging	88	1	-	-	0.9321
5 sekund		76	1	-	-	0.9068
3 sekundy	Boosting	98	-	-	0.5	0.9483
5 sekund		86	-	-	0.5	0.9176

Tabela 5.35: Wyniki eksperymentów najlepszych modeli drzewa decyzyjnego ze wzmocnieniami przy użyciu 3 i 5 sekundowych plików audio.

W Tabelach 5.34 i 5.35 widoczne są wyniki dla eksperymentów w zakresie wzmocnień drzewa decyzyjnego. Znak "−" oznacza, że dane parametry przyjęły wartości domyślne, zgodne z wcześniejszym opisem algorytmów. Najlepszym wzmocnieniem w pierwotnej analizie okazał się las losowy z wynikiem 95.22% (podrozdział 5.5.1), a w przypadku eksperymentów najlepszym okazało się wzmocnienie Boosting z wynikiem 95.68% dla modelu z 50 cechami MFCC. Tuż za nim jest model ze wzmocnieniem lasu losowego z eksperymentem 3 sekundowych plików audio.

Maszyna wektorów nośnych

Liczba cech	Funkcja jądra	C	Dokładność
30	RBF	10	0.9256
50	RGB	10	0.9357

Tabela 5.36: Wyniki eksperymentów najlepszych modeli maszyny wektorów nośnych przy wyodrębnieniu 30 i 50 cech MFCC.

Długość plików	Funkcja jądra	C	Dokładność
3 sekundy	RBF	10	0.9021
5 sekund	RGB	10	0.9055

Tabela 5.37: Wyniki eksperymentów najlepszych modeli maszyny wektorów nośnych przy użyciu 3 i 5 sekundowych plików audio.

W Tabelach 5.36 i 5.37 zaprezentowano najlepsze wyniki dla modeli maszyny wektorów nośnych. W tym przypadku również te modele przewyższają dokładnością pierwotnie najlepszy analizowany model, który osiągnął 90.12% (podrozdział 5.6). Najlepszy wynik osiągnął model dla 50 wyodrębnionych cech MFCC.

Sieci neuronowe

Liczba cech	Ukryte warstwy	Funkcja aktywacji	Algorytm optymalizacji	Współczynnik uczenia	Dokładność
30	(150, 150)	relu	adam	constant	0.9739
50	(150, 150)	relu	adam	constant	0.9808

Tabela 5.38: Wyniki eksperymentów najlepszych modeli sieci neuronowych przy wyodrębnieniu 30 i 50 cech MFCC.

Długość plików	Ukryte warstwy	Funkcja aktywacji	Algorytm optymalizacji	Współczynnik uczenia	Dokładność
3 sekundy	(150, 100)	relu	adam	constant	0.9560
5 sekund	(100, 150)	relu	sgd	adaptive	0.9523

Tabela 5.39: Wyniki eksperymentów najlepszych modeli sieci neuronowych przy użyciu 3 i 5 sekundowych plików audio.

W Tabelach 5.38 i 5.39 widnieją wyniki najlepszych modeli sieci neuronowych. Modele z większą ilością wyodrębnionych cech przewyższają pierwotnie analizowany najlepszy model, który osiągnął wynik około 96% (podrozdział 5.7), ale modele korzystające z plików audio 3 i 5 sekundowych nie poradziły sobie lepiej. Wynik 98% przy wyodrębnionych 50 cechach pokazuje, że ten model świetnie sobie radzi z problemem klasyfikacji instrumentów.

Rozdział 6

Podsumowanie

Wybrane metody uczenia nadzorowanego zostały ocenione na podstawie 5 miar: dokładności klasyfikacji, precyzji, czułości, miary F1 oraz czasu treningu (mierzonego w sekundach). Dokładność była najważniejszym czynnikiem, określającym jakość modeli. W ramach końcowej analizy porównawczej wybrano najlepszych przedstawicieli z każdego analizowanego alogrytmu i umieszczono ich w Tabeli 6.1. Oprócz wybranego kryterium dokładności dodano również czas treningu, by móc dogłębniej spojrzeć na wybrane algorytmy.

Algorytm	Dokładność	Czas treningu
Losowy model bazowy	0.2502	0.0010
Regresja logistyczna	0.8363	18.9385
Naiwny klasyfikator Bayes'a	0.7642	0.0190
Metoda K - najbliższych sąsiadów	0.9517	0.0792
Drzewo decyzyjne	0.9119	0.8952
Wzmocnienia - las losowy	0.9522	6.5843
Maszyna wektorów nośnych	0.9012	7.6117
Sieci neuronowe	0.9623	105.5970

Tabela 6.1: Zbiór metryki dokładności i czasu treningu najlepszych przedstawicieli analizowanych algorytmów.

Wyniki analizy pokazały, że modeli sieci neuronowych osiągnął najlepszy wynik na zestawie testowym wynoszący 96.23% co czyni go najlepszym wyborem w tym przypadku.

Dodatkowo, podczas analizy czasu trenowania, wybrany model sieci neuronowych jest relatywnie efektywny pod względem kosztów obliczeniowych, co czyni go praktycznym rozwiązaniem w rzeczywistych zastosowaniach. Jednakże, chcąc zoptymalizować koszta treningu kosztem dokładności to model metody K - najbliższych sąsiadów również byłby dobrym wyborem, między modelem sieci neuronowej, a tym jest 1 punkt procentowy różnicy w dokładności, a w czasie treningu już można zauważyć mocną różnicę z przewagą na korzyść metody K - najbliższych sąsiadów.

Podsumowując, przeprowadzona analiza umożliwiła wybór algorytmu o najlepszych wynikach, jednocześnie podkreślając znaczenie dokładnej ewaluacji i porównania modeli w procesie uczenia maszynowego. Finalnie wybrany algorytm zapewnia optymalne połączenie wydajności i dokładności w danym scenariuszu zastosowania.

Wyniki eksperymentów również pozwoliły zbadać jakość modeli w zależności od różnego sposobu przetwarzania danych. Model metody K - najbliższych sąsiadów oraz sieci neuronowych z 50 wyodrębnionymi cechami dały ponad 98% dokładności w rozważanym problemie, przewyższając wyniki pierwotnej konfiguracji testowej (z jednosekundowymi plikami audio i 13 wyodrębnionymi cechami MFCC), co czyni je najlepszymi modelami w tym kryterium.

Kontynuując badania warto poszerzyć rozważaną gamę hiperparametrów. W pracy ograniczono się do sprawdzenia możliwości poszczególnych standardowych modeli, ze względów technicznych, ale przy lepszych możliwościach warto również sprawdzić inne mniej standardowe modele. Praca ta również może być wstępem do dalszej analizy dźwięków. Rozważania te można rozszerzyć o inne instrumenty, czy całe ich rodziny. Modele mogą być otwarte na bardziej zaawansowane analizy - wyodrębnianie głównego instrumentu z utworów polifonicznych, czy wyodrębnianie wszystkich instrumentów grających w danych utworach.

Możliwości sztucznej inteligencji otwierają drzwi do nieskończonej możliwości rozwoju w dziedzinie towarzyszącej każdego dnia człowiekowi - muzyki.

Rozdział 7

Dodatek

W tej części zamieszczono informacje o specyfikacji sprzętowej, języku programowania, użytych bibliotek oraz link do reporytorium GitHub.

Specyfikacja sprzętowa

Analizy zostały wykonane na komputerze o następującej specyfikacji sprzętowej:

- Procesor:AMD Ryzen™ 7 4800H
- Pamięć RAM: 32 GB (DDR4, 2666 MHz)
- Karta graficzna: NVIDIA GeForce GTX 1650 Ti AMD Radeon™ Graphics
- Dysk SSD M.2 PCIe: 512 GB
- Urządzenie: Lenovo IdeaPad Gaming 3-15 R7

Oprogramowanie użyte podczas analizy

- System operacyjny: Windows 10 Education
- Wersja Python: 3.12.2
- Dodatkowe pakiety i biblioteki: numpy (1.26.1), matplotlib (3.8.4), pandas (2.2.1), seaborn (0.13.2), tabulate (0.9.0), scikit-learn (1.4.1).

Materiały źródłowe

Wszystkie materiały źródłowe, w tym sktypty zawierające analizy, zostały udostępnione w repozytorium na platformie GitHub:
Link do repozytorium: https://github.com/AagataSobczaak/BSc-Thesis [37].

Bibliografia

[1] Aiedh Mrisi Alharthi, Muhammad Hisyam Lee, Z. A. Improving penalized logistic regression model with missing values in high-dimensional. *International Journal of Online and Biomedical Engineering (iJOE) 18*, 02 (February 2022), 40–54.

[2] Andy Liaw, M. W. Classification and regression by randomForest. *R News 2*, 3 (2002), 18–22.

[3] Basu, J. K., Bhattacharyya, D., hoon Kim, T. Use of artificial neural network in pattern recognition. *International Journal of Software Engineering and Its Applications 4*, 2 (April 2010), 23–34.

[4] Batta, M. Machine learning algorithms - a review. *International Journal of Science and Research (IJSR) 9*, 1 (2020). ResearchGate Impact Factor (2018): 0.28, SJIF (2018): 7.426.

[5] Ben-Yishai, A., Ordentlich, O. Constructing multiclass classifiers using binary classifiers under log-loss. *arXiv preprint arXiv:2102.08184* (2021).

[6] Boswell, D. Introduction to support vector machines. wykład Caltech (2002).

[7] Bruce, P., Bruce, A., Gedeck, P. *Statystyka praktyczna w data science: 50 kluczowych zagadnień w językach R i Python*, wydanie ii ed. Helion SA, Gliwice, Polska, 2021. Tłumaczenie polskie na podstawie oryginału: *Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python, 2nd Edition*, ISBN 9781492072942 © 2020 Peter Bruce, Andrew Bruce, and Peter Gedeck, O'Reilly Media.

[8] Chaudhary, A., Kolhe, S., Kamal, R. An improved random forest classifier for multi-class classification. *Information Processing in Agriculture 3*, 3 (2016), 215–222.

[9] Chavan, R. S., Sable, G. S. An overview of speech recognition using hmm. *International Journal of Computer Science and Mobile Computing (IJCSMC) 2*, 6 (June 2013), 233–238.

[10] Dave, N. Feature extraction methods lpc, plp and mfcc in speech recognition. *International Journal for Advance Research in Engineering and Technology 1*, VI (July 2013).

[11] Dudek, G. Systemy uczące się. wykład 16: Maszyna wektorów nośnych, 2014. Częstochowa.

[12] Elith, J., Leathwick, J. R., Hastie, T. A working guide to boosted regression trees. *Journal of Animal Ecology 77*, 4 (2008), 802–813.

[13] Fadi AlMahamid, K. G. Reinforcement learning algorithms: An overview and classification. *Department of Electrical and Computer Engineering, Western University* (2024).

[14] Foody, G. M. Challenges in the real-world use of classification accuracy metrics: From recall and precision to the matthews correlation coefficient. *PLOS ONE* (October 2023).

[15] Gulati, P., Sharma, A., Gupta, M. Theoretical study of decision tree algorithms to identify pivotal factors for performance improvement: A review. *International Journal of Computer Applications 141*, 14 (May 2016), 19–25.

[16] Ige, T., Kiekintveld, C. Performance comparison and implementation of bayesian variants for network intrusion detection. *arXiv preprint arXiv:2308.11834 2308*, 11834 (August 2023).

[17] J. Klimaszewski, M. Sklyar, M. K. Learning ℓ_1-penalized logistic regressions with smooth approximation. In *2017 IEEE International Conference on Innovations in Intelligent Systems and Applications (INISTA)* (Gdynia, Poland, 2017), pp. 126–130.

[18] Kataria, A., Singh, M. D. A review of data classification using k-nearest neighbour algorithm. *International Journal of Emerging Technology and Advanced Engineering 3*, 6 (June 2013), 354. ISO 9001:2008 Certified Journal.

[19] Kupryjanow, A. Uczenie maszynowe iii - svm. `https://sound.eti.pg.gda.pl/student/isd/isd14-svm.pdf`, 2013. Dostęp: 29 grudnia 2024.

[20] Maciej Wadas, J. S. Performance analysis of the tensorflow library with different optimisation algorithms. *Journal of Computer Science and Information Systems (JCSI) 21* (December 2021), 330–335.

[21] Magre, S. B., Janse, P. V., Deshmukh, R. R. A review on feature extraction and noise reduction technique. *International Journal of Advanced Research in Computer Science and Software Engineering 4*, 2 (February 2014).

[22] Maind, S. B., Wankar, P. Research paper on basic of artificial neural network. *International Journal on Recent and Innovation Trends in Computing and Communication 2*, 1 (2014), 96–100.

[23] Masood, S., Gupta, S., Khan, S. Novel approach for musical instrument identification using neural network. In *Proceedings of the 2015 Annual IEEE India Conference (INDICON)* (December 2015), IEEE.

[24] mfiles.pl. Drzewo decyzyjne – schemat (plik graficzny). `https://mfiles.pl/pl/index.php/Plik:Drzewo_decyzyjne_schemat.jpg`. Dostęp: 2024-12-28.

[25] Mohanty, S. P. Musical instrument's sound dataset, 2022. Dostęp: 8 grudnia 2024.

[26] Oza, A. Fraud detection using machine learning. *Computer Science, Business* (2018).

[27] Pal, M. Ensemble learning with decision tree for remote sensing classification. *Proceedings of World Academy of Science, Engineering and Technology 26* (December 2007), 1307–6884.

[28] Powers, D. M. W. Evaluation: From precision, recall and f-measure to roc, informedness, markedness & correlation. *International Journal of Machine Learning Technology 2*, 1 (2011), 37–63.

[29] Powers, D. M. W. Evaluation: From precision, recall and f-measure to roc, informedness, markedness & correlation. *International Journal of Machine Learning Technology 2*, 1 (2011), 37–63.

[30] Pradhan, A. Support vector machine - a survey. *International Journal of Emerging Technology and Advanced Engineering 2*, 8 (August 2012), 201–206.

[31] Rasamoelina, A. D., Adjaïlia, F., Sincák, P. A review of activation function for artificial neural network. In *SAMI 2020 - IEEE 18th World Symposium on Applied Machine Intelligence and Informatics* (Herľany, Slovakia, 2020), Technical University of Kosice, IEEE, pp. January 23–25.

[32] Riad, S., Mania, J., Bouchaou, L., Najjar, Y. Rainfall-runoff model using an artificial neural network approach. *Mathematical and Computer Modelling 40*, 7-8 (2004), 839–846.

[33] Rish, I. An empirical study of the naïve bayes classifier. Tech. rep., Université de Montréal, January 2001.

[34] Sarker, I. H. Machine learning: Algorithms, real-world applications and research directions. *SN Computer Science* (March 2021).

[35] Science, T. D. Multi-class classification: One-vs-all & one-vs-one, 2024. Dostęp: 28 grudnia 2024.

[36] Shahin, M. A., Jaksa, M. B., Maier, H. R. Artificial neural network applications in geotechnical engineering. *Australian Geomechanics Journal 36*, 1 (March 2001), 49–62.

[37] Sobczak, A. Bsc thesis. GitHub Repository, 2025. Dostęp: 5 stycznia 2025 r,.

[38] STHDA. Penalized logistic regression essentials in r: Ridge, lasso and elastic net, n.d. Dostęp: 27 grudnia 2024.

[39] Su, Y. Instrument classification using different machine learning and deep learning methods. *Highlights in Science, Engineering and Technology 34* (February 2023), 136–142.

[40] Tangirala, S. Evaluating the impact of gini index and information gain on classification using decision tree classifier algorithm. *International Journal of Advanced Computer Science and Applications (IJACSA) 11*, 2 (2020), 612–619.

[41] Tharwat, A. Classification assessment methods. *Applied Computing and Informatics 17* (August 2018), 168–192.

[42] Ting, K. M. *Confusion Matrix*. Springer US, Boston, MA, 2010, pp. 209–209.

[43] Vincent Lemaire, Fabrice Clérot, M. B. An efficient shapley value computation for the naive bayes classifier. *arXiv preprint arXiv:2307.16718 2307*, 16718 (July 2023).

[44] Wikipedia contributors. Drzewo decyzyjne — Wikipedia, wolna encyklopedia. https://pl.wikipedia.org/wiki/Drzewo_decyzyjne. Dostęp: 28 grudnia 2024.

[45] Wikipedia contributors. K-nearest neighbors algorithm — wikipedia, the free encyclopedia. https://en.wikipedia.org/wiki/K-nearest_neighbors_algorithm, 2024. Dostęp: 28 grudnia 2024.

[46] Yu, H., Kim, S. Svm tutorial: Classification, regression and ranking. In *Handbook of Natural Computing*. Springer, Berlin, Heidelberg, 2012, pp. 479–506.